

Beispiel 4.2 Multi season occupancy

Annegret Grimm-Seyfarth

2023-05-16

Multi season Occupancy

Dieses Beispiel verwendet das R-paket “unmarked” fuer eine Demonstration wie die Belegungswahrscheinlichkeit über mehrere Jahre nach MacKenzie berechnet werden kann.

Als erstes muss das unmarked package geladen werden. Der folgende Code, schaut nach, ob es nicht schon installiert ist und installiert es gegebenenfalls.

```
## unmarked  ggplot2  MuMIn
##      TRUE      TRUE   TRUE
```

Fuer dieses Beispiel verwenden wir Daten von Erdkroeten (*Bufo bufo*) in einer Auenlandschaft. Wir wollen die Vorkommenswahrscheinlichkeit in Abhaengigkeit von Umweltparametern berechnen. Die Laichzeit stellt für Amphibien in Deutschland eine optimale Zeit für Bestandserhebungen dar. In einem standardisierten Verfahren wurden alle Amphibien an allen Gewaessern im Naturschutzgebiet der Papitzer Lehmlachen bei Leipzig mittels akustischer und visueller Verfahren erhoben. Jede Art wurde zu ihrem jeweiligen Laichzeitraum in den Jahren 2013, 2014, 2015 und 2018 erfasst. Wir wollen die Analysen hier am Beispiel der Erdkroete darstellen. Es fanden 2013 6, 2014 7, 2015 5 und 2018 ebenfalls 5 Begehungen statt. Um einen Vergleich über die Jahre möglich zu machen, wird eine Nachweisgeschichte mit je 7 Erfassungen pro Jahr (= Saison) erstellt, wobei nicht begangene Tage oder Gewaesser pro Saison, inkl. der nicht begangenen Tage in 2016 und 2017, mit „NA“ gekennzeichnet wurden, um sie von einer tatsächlichen Nicht-Beobachtung (0) unterscheiden zu können. Eine Reihe an Erfassungs- (z.B. Wetter) und Standortparametern (z.B. Habitatparameter) wurden parallel und über alle Jahre identisch erfasst.

```
#fn <- system.file('extdata', "Erdkroete_JV.csv", package = "ULmerBuch")
# 35 Gewaesser mit 7 Besuchen pro Gewaesser und Jahr ueber 6 Jahre
#EK <- read.csv2(fn, row.names = "Pond")
EK <- read.csv2("extdata/Erdkroete_JV.csv", row.names = "Pond",
stringsAsFactors = TRUE)
```

1. Erdkroeten an/abwesend

```
dim(EK)  #
```

```
## [1]  35 152
```

```
# 35 Gewaesser, 152 Spalten
```

Artbeobachtungen

head(EK[,1:42])

##	S1_13	S2_13	S3_13	S4_13	S5_13	S6_13	S7_13	S1_14	S2_14	S3_14	S4_14	S5_14
## 1	NA	1	NA	1	NA	1	0	1	0	0	0	0
## 2	1	NA	NA	1	NA	1	NA	1	1	1	1	0
## 3	NA	0	0	0	NA	0	0	1	0	0	0	0
## 3b	1	NA	NA	1	NA	0	NA	1	1	0	0	0
## 4	NA	1	NA	NA	NA	1	NA	1	0	0	0	0
## 5	NA	1	NA	NA	NA	1	NA	1	0	0	0	0

##	S6_14	S7_14	S1_15	S2_15	S3_15	S4_15	S5_15	S6_15	S7_15	S1_16	S2_16	S3_16
## 1	0	0	1	1	0	0	0	NA	NA	NA	NA	NA
## 2	1	1	0	1	0	0	1	NA	NA	NA	NA	NA
## 3	0	0	0	0	0	0	0	NA	NA	NA	NA	NA
## 3b	0	1	0	0	0	0	1	NA	NA	NA	NA	NA
## 4	1	0	0	0	0	0	0	NA	NA	NA	NA	NA
## 5	1	0	0	0	0	0	0	NA	NA	NA	NA	NA

##	S4_16	S5_16	S6_16	S7_16	S1_17	S2_17	S3_17	S4_17	S5_17	S6_17	S7_17	S1_18
## 1	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	1
## 2	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	1
## 3	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	0
## 3b	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	1
## 4	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	1
## 5	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	1

##	S2_18	S3_18	S4_18	S5_18	S6_18	S7_18
## 1	1	1	1	0	NA	NA
## 2	1	1	1	1	NA	NA
## 3	0	1	0	0	NA	NA
## 3b	1	1	1	1	NA	NA
## 4	1	1	1	0	NA	NA
## 5	1	1	1	1	NA	NA

Spalten S1_13 (Survey 1, Jahr 2013) bis S7_18 (Survey 7, Jahr 2018)

Tagesspezifische Parameter (= obsCovs) sind folgende:

head(EK[,43:126])

##	B1_13	B2_13	B3_13	B4_13	B5_13	B6_13	B7_13	B1_14	B2_14	B3_14	B4_14	B5_14
## 1	NA	2	NA	2	NA	3	2	2	2	2	2	2
## 2	1	NA	NA	2	NA	3	NA	2	2	2	2	2
## 3	NA	2	2	2	NA	3	2	2	2	2	2	2
## 3b	1	NA	NA	2	NA	3	NA	2	2	2	2	2
## 4	NA	2	NA	NA	NA	3	NA	2	2	2	2	2
## 5	NA	2	NA	NA	NA	3	NA	2	2	2	2	2

##	B6_14	B7_14	B1_15	B2_15	B3_15	B4_15	B5_15	B6_15	B7_15	B1_16	B2_16	B3_16
## 1	2	2	2	3	2	2	2	2	2	NA	NA	NA
## 2	2	2	2	3	2	2	2	2	2	NA	NA	NA
## 3	2	2	2	3	2	2	2	2	2	NA	NA	NA
## 3b	2	2	2	3	2	2	2	2	2	NA	NA	NA
## 4	2	2	2	3	2	2	2	2	2	NA	NA	NA
## 5	2	2	2	3	2	2	2	2	2	NA	NA	NA

##	B4_16	B5_16	B6_16	B7_16	B1_17	B2_17	B3_17	B4_17	B5_17	B6_17	B7_17
----	-------	-------	-------	-------	-------	-------	-------	-------	-------	-------	-------

S1_18.1											
## 1	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2											
## 2	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2											
## 3	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2											
## 3b	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2											
## 4	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2											
## 5	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2											
##	B2_18	B3_18	B4_18	B5_18	B6_18	B7_18	LTemp1_13	LTemp2_13	LTemp3_13	LTemp4_13	
## 1	3	1	1	1	NA	NA	9.2	11.7	16.5	15.7	
## 2	3	1	1	1	NA	NA	9.2	11.7	16.5	15.7	
## 3	3	1	1	1	NA	NA	9.2	11.7	16.5	15.7	
## 3b	3	1	1	1	NA	NA	9.2	11.7	16.5	15.7	
## 4	3	1	1	1	NA	NA	9.2	11.7	16.5	15.7	
## 5	3	1	1	1	NA	NA	9.2	11.7	16.5	15.7	
##	LTemp5_13	LTemp6_13	LTemp7_13	LTemp1_14	LTemp2_14	LTemp3_14	LTemp4_14				
## 1	16.8	16.1	16.9	14.8	6.4	4.6	5.4				
## 2	16.8	16.1	16.9	14.8	6.4	4.6	5.4				
## 3	16.8	16.1	16.9	14.8	6.4	4.6	5.4				
## 3b	16.8	16.1	16.9	14.8	6.4	4.6	5.4				
## 4	16.8	16.1	16.9	14.8	6.4	4.6	5.4				
## 5	16.8	16.1	16.9	14.8	6.4	4.6	5.4				
##	LTemp5_14	LTemp6_14	LTemp7_14	LTemp1_15	LTemp2_15	LTemp3_15	LTemp4_15				
## 1	6.5	9.5	10.9	7.2	6.7	3.6	4.6				
## 2	6.5	9.5	10.9	7.2	6.7	3.6	4.6				
## 3	6.5	9.5	10.9	7.2	6.7	3.6	4.6				
## 3b	6.5	9.5	10.9	7.2	6.7	3.6	4.6				
## 4	6.5	9.5	10.9	7.2	6.7	3.6	4.6				
## 5	6.5	9.5	10.9	7.2	6.7	3.6	4.6				
##	LTemp5_15	LTemp6_15	LTemp7_15	LTemp1_16	LTemp2_16	LTemp3_16	LTemp4_16				
## 1	13.8	NA	NA	NA	NA	NA	NA				
## 2	13.8	NA	NA	NA	NA	NA	NA				
## 3	13.8	NA	NA	NA	NA	NA	NA				
## 3b	13.8	NA	NA	NA	NA	NA	NA				
## 4	13.8	NA	NA	NA	NA	NA	NA				
## 5	13.8	NA	NA	NA	NA	NA	NA				
##	LTemp5_16	LTemp6_16	LTemp7_16	LTemp1_17	LTemp2_17	LTemp3_17	LTemp4_17				
## 1	NA	NA	NA	NA	NA	NA	NA				
## 2	NA	NA	NA	NA	NA	NA	NA				

```
## 3      NA      NA      NA      NA      NA      NA      NA
## 3b     NA      NA      NA      NA      NA      NA      NA
## 4      NA      NA      NA      NA      NA      NA      NA
## 5      NA      NA      NA      NA      NA      NA      NA
##      LTemp5_17 LTemp6_17 LTemp7_17 LTemp1_18 LTemp2_18 LTemp3_18 LTemp4_18
## 1      NA      NA      NA      14.1      9.5      5.9      11.8
## 2      NA      NA      NA      14.1      9.5      5.9      11.8
## 3      NA      NA      NA      14.1      9.5      5.9      11.8
## 3b     NA      NA      NA      14.1      9.5      5.9      11.8
## 4      NA      NA      NA      14.1      9.5      5.9      11.8
## 5      NA      NA      NA      14.1      9.5      5.9      11.8
##      LTemp5_18 LTemp6_18 LTemp7_18
## 1      14.8      NA      NA
## 2      14.8      NA      NA
## 3      14.8      NA      NA
## 3b     14.8      NA      NA
## 4      14.8      NA      NA
## 5      14.8      NA      NA
```

Spalten B1_13 (Beschattung zu Survey 1, Jahr 2013) bis B7_18 (Beschattung zu Survey 7, Jahr 2018)

Spalten LTemp1_13 (Lufttemperatur zu Survey 1, Jahr 2013) bis LTemp7_18 (Lufttemperatur zu Survey 7, Jahr 2018)

Jahresspezifische Plotparameter (= yearlySiteCovs) sind folgende:

```
head(EK[,127:150])
```

```
##      Roehrichtguertel_13 Roehrichtguertel_14 Roehrichtguertel_15
## 1      0.50      0.75      0.05
## 2      0.50      0.50      0.05
## 3      0.05      0.75      0.05
## 3b     0.05      0.05      0.05
## 4      0.50      0.75      0.05
## 5      0.50      0.75      0.50
##      Roehrichtguertel_16 Roehrichtguertel_17 Roehrichtguertel_18
## 1      0.5      0.5      0.05
## 2      0.5      0.5      0.50
## 3      0.5      0.5      0.05
## 3b     0.5      0.5      0.05
## 4      0.5      0.5      0.05
## 5      0.5      0.5      0.50
##      Schwimmblattpflanzen_13 Schwimmblattpflanzen_14 Schwimmblattpflanzen_15
## 1      0.5      0.75      0.50
## 2      0.5      0.50      0.50
## 3      0.5      0.75      0.75
## 3b     0.5      0.50      0.50
## 4      0.5      0.50      0.50
## 5      0.5      0.50      0.50
##      Schwimmblattpflanzen_16 Schwimmblattpflanzen_17 Schwimmblattpflanzen_18
## 1      0.5      0.5      0.05
## 2      0.5      0.5      0.05
```

```

## 3          0.5          0.5          0.50
## 3b         0.5          0.5          0.05
## 4          0.5          0.5          0.05
## 5          0.5          0.5          0.05
##   Sum_Rain_13 Sum_Rain_14 Sum_Rain_15 Sum_Rain_16 Sum_Rain_17 Sum_Rain_18
## 1          99.5         45.1         67.7         105         93.4         79.6
## 2          99.5         45.1         67.7         105         93.4         79.6
## 3          99.5         45.1         67.7         105         93.4         79.6
## 3b         99.5         45.1         67.7         105         93.4         79.6
## 4          99.5         45.1         67.7         105         93.4         79.6
## 5          99.5         45.1         67.7         105         93.4         79.6
##   Tage_5_Grad_13 Tage_5_Grad_14 Tage_5_Grad_15 Tage_5_Grad_16
Tage_5_Grad_17
## 1          23          74          41          48
63
## 2          23          74          41          48
63
## 3          23          74          41          48
63
## 3b         23          74          41          48
63
## 4          23          74          41          48
63
## 5          23          74          41          48
63
##   Tage_5_Grad_18
## 1          39
## 2          39
## 3          39
## 3b         39
## 4          39
## 5          39

# Roehrichtguertel_13 bis Roehrichtguertel_18 (Prozentuale Bedeckung der
Gewaesser mit Roehricht pro Jahr)
# Schwimmblattpflanzen_13 bis Schwimmblattpflanzen_18 (Prozentuale Bedeckung
der Gewaesser mit Schwimmblattpflanzen pro Jahr)
# Sum_Rain_13 bis Sum_Rain_18 (Aufsummierter Niederschlag des Fruehjahren pro
Jahr)
# Tage_5_Grad_13 bis Tage_5_Grad_18 (Anzahl Tage ueber 5°C im Fruehjahr pro
Jahr)

## Plotspezifische Parameter (= siteCovs) sind folgende:
head(EK[,151:152])


##   Wasserversorgung   Flaeche
## 1      indirekt  3532.35
## 2      direkt   9479.99
## 3      indirekt   712.23
## 3b     direkt   1043.63

```

```
## 4          direkt 3087.35
## 5          indirekt 23454.20

# Wasserversorgung (direkt gespeist, indirekt durch Drueckwasser gespeist,
# keine Wasserspeisung)
# Flaeche (Wasserflaeche in qm)

# Summierte Anzahl der Erdkroeten-Beobachtungen ueber alle 35 Gewaesser
barplot(table(rowSums(EK[,1:42], na.rm=TRUE)))
```



Aufbereiten der Daten in das unmarked format

Wir muessen die Daten noch umformatieren mittels der `unmarkedFrameOccu` function. Dazu definieren wir zunaechst die Artbeobachtungsdaten und die einzelnen Parameter.

```
# Artbeobachtungen
y.EK <- EK[,1:42]
y.EK <- as.matrix(y.EK)

# Parameter für den Jahreseffekt (seasonal effect im unmarked frame)
year <- as.character(2013:2018)
years <- matrix(year, nrow(y.EK), 6, byrow=TRUE)

# Parameter pro Survey bzw. pro Jahr als Matrix schreiben
cloud <- as.matrix(EK[,43:84])
air <- as.matrix(EK[,85:126])
Roehrrechtguertel <- as.matrix(EK[,127:132])
Schwimtblattpflanzen <- as.matrix(EK[,133:138])
```

```

Sum_Rain <- as.matrix(EK[,139:144])
more5degree <- as.matrix(EK[,145:150])

#NA-Werte anpassen
y.EK[is.na(cloud) != is.na(y.EK)] <- NA

### Datensatz umformatieren, wobei numPrimary die Anzahl Primärperioden, also
Jahre in unserem Fall, darstellt
sample.EK <- unmarkedMultFrame(y=y.EK,
                                siteCovs= EK[,151:152],
                                yearlySiteCovs=list(year=years,
                                                       Roehrichtguertel=
Roehrichtguertel,
                                                       Schwimmblattpflanzen=
Schwimmblattpflanzen,
                                                       Sum_Rain = Sum_Rain,
                                                       more5degree=more5degree),
                                obsCovs = list(cloud=cloud, air = air),
                                numPrimary=6)

## Warning: yearlySiteCovs contains characters. Converting them to factors.

```

Unmarked hat eine Summary funktion, welche die Daten uebersichtlich zusammenfasst

```

summary(sample.EK)

## unmarkedFrame Object
##
## 35 sites
## Maximum number of observations per site: 42
## Mean number of observations per site: 16.14
## Number of primary survey periods: 6
## Number of secondary survey periods: 7
## Sites with at least one detection: 33
##
## Tabulation of y observations:
##      0      1 <NA>
## 317 248 905
##
## Site-level covariates:
## Wasserversorgung   Flaeche
## direkt   : 4      Min.    : 72.52
## indirekt:12      1st Qu.: 1476.59
## keine    :19      Median : 3284.48
##                      Mean   : 6804.60
##                      3rd Qu.: 7867.69
##                      Max.   :40517.50
##
## Observation-level covariates:
##      cloud      air
## Min.    :1.000  Min.    : 3.600
## 1st Qu.:2.000  1st Qu.: 6.475

```

```
## Median :2.000   Median :10.200
## Mean   :1.932   Mean    :10.542
## 3rd Qu.:2.000   3rd Qu.:14.800
## Max.    :3.000   Max.    :16.900
## NA's    :823     NA's    :630
##
## Yearly-site-level covariates:
##   year   Roehrichtguertel Schwimmblattpflanzen   Sum_Rain
## 2013:35   Min.    :0.0500   Min.    :0.0500   Min.    : 45.10
## 2014:35   1st Qu.:0.0500   1st Qu.:0.5000   1st Qu.: 67.70
## 2015:35   Median :0.5000   Median :0.5000   Median : 86.50
## 2016:35   Mean    :0.3482   Mean    :0.4228   Mean    : 81.72
## 2017:35   3rd Qu.:0.5000   3rd Qu.:0.5000   3rd Qu.: 99.50
## 2018:35   Max.    :0.7500   Max.    :0.7500   Max.    :105.00
## more5degree
## Min.    :23.0
## 1st Qu.:39.0
## Median :44.5
## Mean    :48.0
## 3rd Qu.:63.0
## Max.    :74.0
```

Einfaches Belegungsmodell pro Jahr ohne Kovariable

```
occu.m1 <- colext(~1, #occupancy keine Kovariable
                 ~year-1, #colonization keine Kovariable aber jahresabhängig
                 ~year-1, #extinction keine Kovariable aber jahresabhängig
                 ~year #detection keine Kovariable aber jahresabhängig
                 , data = sample.EK)
```

Die normale Zusammenfassung zeigt die Schätzungen auf der logit-scale, was nicht allzusehr weiterhilft.

```
summary(occu.m1)

##
## Call:
## colext(psiformula = ~1, gammaformula = ~year - 1, epsilonformula = ~year -
##      1, pformula = ~year, data = sample.EK)
##
## Initial (logit-scale):
##   Estimate      SE      z P(>|z|)
##      1.35 0.575 2.35  0.019
##
## Colonization (logit-scale):
##           Estimate      SE      z P(>|z|)
## year2013  9.23e-01   1.11  8.32e-01  0.405
## year2014 -6.37e+00  31.51 -2.02e-01  0.840
## year2015  0.00e+00 112.38  0.00e+00  1.000
## year2016  1.53e-10 114.40  1.34e-12  1.000
## year2017  2.24e+00  66.76  3.36e-02  0.973
##
## Extinction (logit-scale):
```



```
##           Estimate      SE      z P(>|z|)
## year2013 -2.51e+00    1.05 -2.38e+00 0.0171
## year2014 -9.22e+00   52.74 -1.75e-01 0.8612
## year2015  0.00e+00  112.38  0.00e+00 1.0000
## year2016 -1.53e-10  114.40 -1.34e-12 1.0000
## year2017 -2.24e+00   66.76 -3.36e-02 0.9732
##
## Detection (logit-scale):
##           Estimate      SE      z P(>|z|)
## (Intercept)  1.594    0.561  2.84 4.50e-03
## year2014     -1.838    0.583 -3.15 1.61e-03
## year2015     -2.842    0.609 -4.67 3.05e-06
## year2016      0.000  112.379  0.00 1.00e+00
## year2017      0.000  112.379  0.00 1.00e+00
## year2018     -0.949    0.592 -1.60 1.09e-01
##
## AIC: 659.9695
## Number of sites: 35
## optim convergence code: 0
## optim iterations: 35
## Bootstrap iterations: 0
```

Die Estimates sind auf der logit Skala und daher fuer uns nicht interpretierbar. Mittels der predict function, koennen wir aber die Belegung in Anwesend/Abwesend umwandeln. Hier steht *psi* fuer die Occupancy.

```
predict(occu.m1, newdata = data.frame(year = 2013), type = "psi")

## Predicted      SE      lower      upper
## 1 0.7940551 0.09407504 0.5552813 0.9225176
```

Als erstes Ergebniss erfahren wir, dass initial etwa 79% aller Gewaesser besetzt waren.

Weiterhin moechten wir noch die Nachweiswahrscheinlichkeit p berechnen. Da wir in unserem Model die Nachweiswahrscheinlichkeit als konstant fuer alle Sites, lediglich variabel zwischen den Jahren angenommen haben, ist es egal fuer welche site wir die Nachweiswahrscheinlichkeit berechnen.

```
predict(occu.m1, newdata = data.frame(year = as.factor(2013:2018)), type =
"det")

## Predicted      SE      lower      upper
## 1 0.8311125 0.07873681 6.210718e-01 0.9366102
## 2 0.4392155 0.03882327 3.651035e-01 0.5161414
## 3 0.2229362 0.04104244 1.527769e-01 0.3133964
## 4 0.8311125 15.77419211 1.081116e-95 1.0000000
## 5 0.8311125 15.77419211 1.081116e-95 1.0000000
## 6 0.6558348 0.04289424 5.676628e-01 0.7344370
```

Wir sehen, dass die Nachweiswahrscheinlichkeit p von 2013 bis 2015 con 83,11% auf 22,29% abgenommen hat, 2016 und 2017 nimmt sie aufgrund fehlender

Beobachtungsdaten die initiale Nachweiswahrscheinlichkeit an und 2018 ist diese im Vergleich zu 2014 und 2015 wieder gestiegen (65,58%).

Nun können wir uns auch die Extinktion (ext) und Kolonisierung (col) anschauen. Da beide Prozesse nur zwischen den Jahren stattfinden können, lassen wir das Endjahr jeweils aus.

```
predict(occu.m1, newdata = data.frame(year = as.factor(2013:2017)), type = "ext")
```

##	Predicted	SE	lower	upper
## 1	0.0750294763	0.073094921	1.018912e-02	0.3899391
## 2	0.0000989502	0.005217818	1.275438e-49	1.0000000
## 3	0.5000000000	28.094697159	2.202935e-96	1.0000000
## 4	0.5000000000	28.600493421	4.176990e-98	1.0000000
## 5	0.0961416394	5.800994942	1.599428e-58	1.0000000

```
predict(occu.m1, newdata = data.frame(year = as.factor(2013:2017)), type = "col")
```

##	Predicted	SE	lower	upper
## 1	0.715655037	0.22566015	2.226205e-01	0.9567473
## 2	0.001709714	0.05377684	2.596391e-30	1.0000000
## 3	0.5000000000	28.09469716	2.202935e-96	1.0000000
## 4	0.5000000000	28.60049342	4.176990e-98	1.0000000
## 5	0.903858361	5.80099494	1.413651e-56	1.0000000

Wir sehen, dass die Kolonisierung von 2013-2014 bei 71% lag, dann stark abnahm und von 2017-2018 wieder sehr stark zunahm.

Schätzungen der Belegungswahrscheinlichkeit in den Folgejahren müssen aus den Schätzungen der Belegung im ersten Jahr und den beiden Parametern, die die Dynamik bestimmen, Extinktion und Kolonisierung, abgeleitet werden. *unmarked* kennt zwei Wege dies zu tun.

```
projected(occu.m1)
```

##		1	2	3	4	5	6
## unoccupied	0.2059449	0.1181369	0.1180222	0.5	0.5	0.09614164	
## occupied	0.7940551	0.8818631	0.8819778	0.5	0.5	0.90385836	

Dieser Datensatz enthält einen Array mit 35 Datenframes, je eins pro Gewässer. Jeder Datenframe enthält die abgeleitete Schätzung von Abwesenheit und Belegung (Zeilen) pro Jahr (Spalten). Da wir hier keinen Unterschied pro Gewässer berücksichtigen, sind alle 35 Datenframes identisch - es wird daher nur eine Gesamtschätzung angezeigt. Die Jahre ohne Artdaten wurden von *unmarked* auf 50% gesetzt.

```
smoothed(occu.m1)
```

##		1	2	3	4	5	6
## unoccupied	0.2059458	0.1183946	0.1180385	0.5	0.5	0.09613875	
## occupied	0.7940542	0.8816054	0.8819615	0.5	0.5	0.90386125	

Im Gegensatz zu *projected* bekommt man mit *smoothed* einen Rückschluss auf den Anteil der belegten Standorte und nicht auf die Gesamtpopulation der Standorte. Somit handelt es sich bei den *projected* Werten um Schätzungen der Populationsparameter und bei den *smoothed* Schätzungen um die Mengen endlicher Stichproben.

Mithilfe der Bootstrap Methode bekommt man zu diesen Schätzungen auch Standardfehler.

```
occu.m1 <- nonparboot(occu.m1, B = 10) # fuer gute Schaetzungen sollte man B
deutlich hoeher saetzen, was aber eine hoehere Berechnungszeit zur Folge hat
cbind(smoothed=smoothed(occu.m1)[2,], SE=occu.m1@smoothed.mean.bsse[2,])
```

```
##      smoothed      SE
## 1 0.7940542 6.182532e-02
## 2 0.8816054 6.542306e-02
## 3 0.8819615 5.385154e-02
## 4 0.5000000 0.000000e+00
## 5 0.5000000 1.772193e-10
## 6 0.9038612 6.195322e-02
```

Nun haben wir fuer jedes Jahr eine Schaetzung der Vorkommenwahrscheinlichkeit und deren Standardfehler, aus dem man wiederum ein Konfidenzintervall berechnen koennte.

Occupancy mit Kovariablen

Unser Erdkroetendatensatz war bereits fuer die Berechnung mit Kovariablen formatiert. Nun kann man mittels Modellvergleiche herausfinden, welche der Kovariablen tatsaechlich einen Einfluss auf Nachweis- und Vorkommenswahrscheinlichkeit haben. Wir beginnen hierzu mit der Nachweiswahrscheinlichkeit. Wir nehmen an, dass diese von Bedeckung, Lufttemperatur, Niederschlag und der Anzahl Tage ueber 5 Grad Celsius abhaengen koennte (bezogen auf die Aktivität von Erdkroeten). Zusaetzlich nehmen wir an, dass alle Parameter sich zwischen den Jahren unterscheiden, was nicht unbedingt durch die aufgenommenen Parameter erklart werden kann.

```
fm1 <- colext(~ 1, ~year-1, ~year-1, ~cloud + air + Sum_Rain + more5degree,
data = sample.EK)
```

```
summary(fm1)
```

```
##
## Call:
## colext(psiformula = ~1, gammaformula = ~year - 1, epsilonformula = ~year -
##      1, pformula = ~cloud + air + Sum_Rain + more5degree, data = sample.EK)
##
## Initial (logit-scale):
##      Estimate      SE      z P(>|z|)
##      1.41 0.572 2.46 0.0138
##
## Colonization (logit-scale):
##      Estimate      SE      z P(>|z|)
## year2013      0.846    1.1 0.771 0.441
## year2014     -5.731   22.8 -0.251 0.802
```

[illegible]

```

## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
# auch das braucht aufgrund von der Berechnung aller Modellkombinationen
etwas Zeit.
head(mx1)

## Global model call: colext(psiformula = ~1, gammaformula = ~year - 1,
epsilonformula = ~year -
##      1, pformula = ~cloud + air + Sum_Rain + more5degree, data = sample.EK)
## ---
## Model selection table
##      psi(Int) p(Int) psi(Int) p(Int) col(yer) ext(yer) p(air)  p(cld) p(mr5)
## 14      1.406 -15.95      1.406 -15.95      +      + 0.166      0.1152
## 30      1.406 -15.95      1.406 -15.95      +      + 0.166      0.1152
## 46      1.406 -15.95      1.406 -15.95      +      + 0.166      0.1152
## 62      1.406 -15.95      1.406 -15.95      +      + 0.166      0.1152
## 16      1.407 -16.47      1.407 -16.47      +      + 0.166 0.07335 0.1181
## 32      1.407 -16.47      1.407 -16.47      +      + 0.166 0.07335 0.1181
##      p(Sum_Ran) df    logLik    AIC delta weight
## 14      0.1287 15 -298.091 626.2 0.00 0.209
## 30      0.1287 15 -298.091 626.2 0.00 0.209
## 46      0.1287 15 -298.091 626.2 0.00 0.209
## 62      0.1287 15 -298.091 626.2 0.00 0.209
## 16      0.1323 16 -298.020 628.0 1.86 0.082
## 32      0.1323 16 -298.020 628.0 1.86 0.082
## Models ranked by AIC(x)

```

Die Parameter fuer die Nachweiswahrscheinlichkeit finden wir in der Modellvergleichstabelle indiziert mit p(). Das beste Modell mit dem geringsten AIC-Wert beinhaltet die Parameter Lufttemperatur, Anzahl der Tage über 5°C und der Niederschlagsmenge. Schauen wir uns die Ergebnisse des ersten Modelles einmal an.

```
get.models(mx1, subset=1)
```

```

## `$`14`
##
## Call:
## colext(psiformula = ~1, gammaformula = ~0 + year, epsilonformula = ~0 +
##       year, pformula = ~air + more5degree + Sum_Rain + 1, data = sample.EK)
##
## Initial:
##      Estimate      SE      z P(>|z|)
##          1.41 0.572 2.46  0.014

## Warning in sqrt(diag(vcov(obj, fixedOnly = fixedOnly))): NaNs wurden
erzeugt

## Colonization:
##      Estimate      SE      z P(>|z|)
## year2013      0.848    1.1  0.771  0.44
## year2014     -10.526 140.3 -0.075  0.94
## year2015      0.000 146.5  0.000  1.00
## year2016      0.000   NaN   NaN   NaN
## year2017      2.786   NaN   NaN   NaN

## Warning in sqrt(diag(vcov(obj, fixedOnly = fixedOnly))): NaNs wurden
erzeugt

## Extinction:
##      Estimate      SE      z P(>|z|)
## year2013     -2.48    1.0 -2.469  0.0135
## year2014     -8.39   46.8 -0.179  0.8579
## year2015      0.00 146.5  0.000  1.0000
## year2016      0.00   NaN   NaN   NaN
## year2017     -2.79   NaN   NaN   NaN
##
## Detection:
##      Estimate      SE      z P(>|z|)
## (Intercept)  -15.951 3.1953 -4.99 5.97e-07
## air           0.166 0.0310  5.36 8.32e-08
## more5degree   0.115 0.0268  4.29 1.77e-05
## Sum_Rain      0.129 0.0289  4.45 8.68e-06
##
## AIC: 626.1824
##
## attr(,"rank")
## function (x)
## do.call("rank", list(x))
## <environment: 0x000001a4a7401b48>
## attr(,"call")
## AIC(x)
## attr(,"class")
## [1] "function"      "rankFunction"
## attr(,"beta")
## [1] "none"

```

Alle drei Kovariablen beeinflussen die Nachweiswahrscheinlichkeit positiv. Nun schauen wir uns noch an, wie die relative Wichtigkeit der Parameter untereinander aussieht. Dazu lassen wir uns die Summe aller AIC-Wichtungen pro Parameter ausgeben:

```
sw(mx1)

##               col(year) ext(year) p(air) p(Sum_Rain) p(more5degree)
## Sum of weights:      1.00      1.00      1.00      0.99      0.99
## N containing models:   64       64       32      32       32
##               p(cloud)
## Sum of weights:      0.28
## N containing models:   32
```

Am wichtigsten erscheint die Lufttemperatur ($\omega_{AIC} = 1$), gefolgt von der Anzahl der Tage über 5°C ($\omega_{AIC} = 0,99$) und der Niederschlagsmenge ($\omega_{AIC} = 0,99$). Alle anderen Parameter spielen für den Nachweis von Erdkroeten zumindest in diesem Gebiet, keine Rolle.

Das koennen wir nun auf neue Daten projizieren und grafisch darstellen. Starten wir mit der Abhaengigkeit von Lufttemperatur:

```
fmx1.fin <- colext(~ 1, ~year-1, ~year-1, ~ air + Sum_Rain + more5degree,
data = sample.EK)

# nur Lufttemperatur wechselt
nd1 <- data.frame(air = 3:17,
                  more5degree = mean(more5degree),
                  Sum_Rain = mean(Sum_Rain))

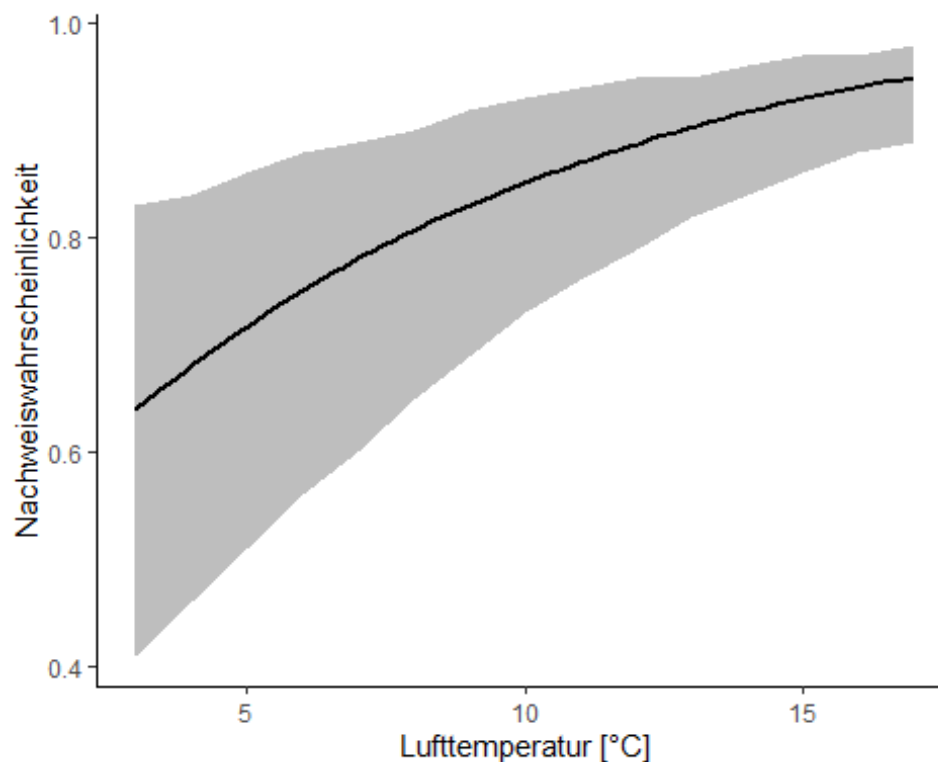
det.1 <- round(predict(fmx1.fin, type="det" , newdata=nd1, appedData = TRUE
),2)
det.1

##      Predicted      SE lower upper
## 1          0.64 0.11  0.41  0.83
## 2          0.68 0.10  0.46  0.84
## 3          0.72 0.09  0.51  0.86
## 4          0.75 0.08  0.56  0.88
## 5          0.78 0.07  0.60  0.89
## 6          0.81 0.07  0.65  0.90
## 7          0.83 0.06  0.69  0.92
## 8          0.85 0.05  0.73  0.93
## 9          0.87 0.04  0.76  0.94
## 10         0.89 0.04  0.79  0.95
## 11         0.90 0.03  0.82  0.95
## 12         0.92 0.03  0.84  0.96
## 13         0.93 0.03  0.86  0.97
## 14         0.94 0.02  0.88  0.97
## 15         0.95 0.02  0.89  0.98

df.det1 <- as.data.frame(cbind(nd1,det.1))
head(df.det1)
```

```
##      air more5degree Sum_Rain Predicted    SE lower upper
## 1    3          48 81.71667    0.64 0.11  0.41  0.83
## 2    4          48 81.71667    0.68 0.10  0.46  0.84
## 3    5          48 81.71667    0.72 0.09  0.51  0.86
## 4    6          48 81.71667    0.75 0.08  0.56  0.88
## 5    7          48 81.71667    0.78 0.07  0.60  0.89
## 6    8          48 81.71667    0.81 0.07  0.65  0.90
```

```
ggplot(data = df.det1, aes(x = air, y = Predicted)) +
  geom_ribbon(aes(ymin = lower, ymax = upper), fill = "gray") +
  stat_smooth(method = "loess", col = "black", se = FALSE) +
  labs(x = "Lufttemperatur [°C]", y = "Nachweiswahrscheinlichkeit") +
  theme_classic()
```



Schauen wir uns noch die Abhaengigkeit von Niederschlag an:

```
# nur Niederschlag wechselt
nd2 <- data.frame(air = mean(air, na.rm=TRUE),
                  more5degree = mean(more5degree),
                  Sum_Rain = 40:110)

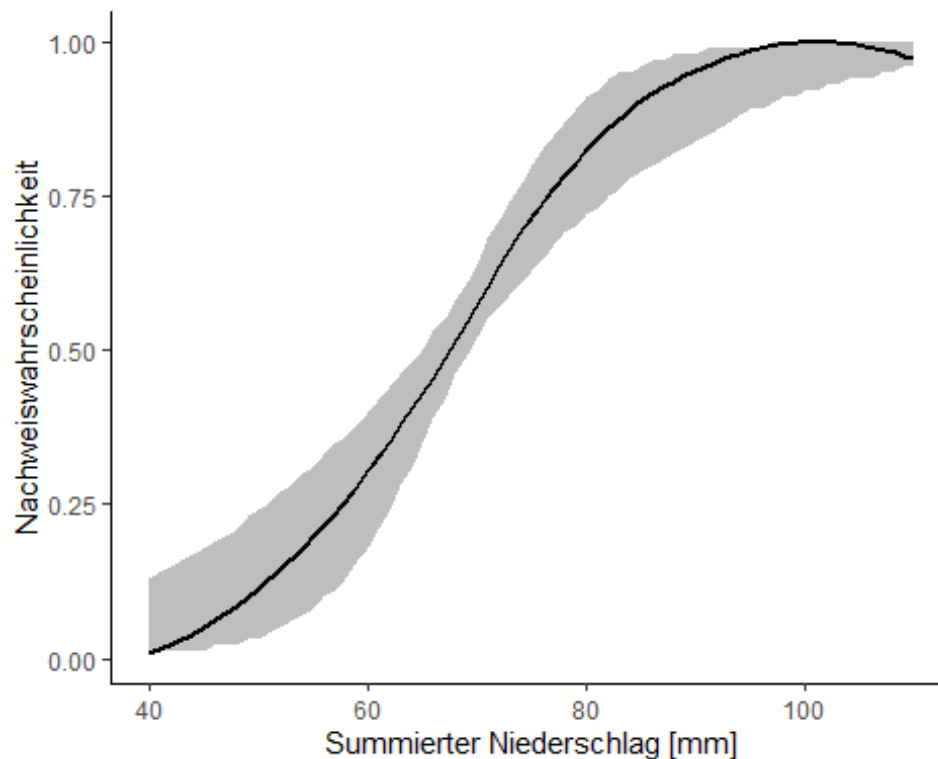
det.2 <- round(predict(fmx1.fin, type="det" , newdata=nd2, appedData = TRUE
),2)
df.det2 <- as.data.frame(cbind(nd2,det.2))
head(df.det2)

##      air more5degree Sum_Rain Predicted    SE lower upper
## 1 10.54167          48      40    0.03 0.02  0.01  0.13
## 2 10.54167          48      41    0.03 0.03  0.01  0.14
```



```
## 3 10.54167      48      42      0.04 0.03 0.01 0.15
## 4 10.54167      48      43      0.04 0.03 0.01 0.16
## 5 10.54167      48      44      0.05 0.03 0.01 0.17
## 6 10.54167      48      45      0.05 0.04 0.01 0.18
```

```
ggplot(data = df.det2, aes(x = Sum_Rain, y = Predicted)) +
  geom_ribbon(aes(ymin = lower, ymax = upper), fill = "gray") +
  stat_smooth(method = "loess", col = "black", se = FALSE) +
  labs(x = "Summierter Niederschlag [mm]", y =
"Nachweiswahrscheinlichkeit") +
  theme_classic()
```



Als naechstes schauen wir uns an, welche Parameter die Vorkommenswahrscheinlichkeit von Erdkroeten beeinflusst.

```
fmx2 <- colext(~ Wasserversorgung + Schwimmblattpflanzen + Roehrichtguertel +
Flaeche, ~year-1, ~year-1, ~ air + more5degree + Sum_Rain, data = sample.EK)
```

```
# Modellselektion
```

```
# alle bekannten Parameter bleiben gleich
```

```
# auch das braucht einiges an Computerzeit
```

```
mx2<-dredge(fmx2, rank="AIC", fixed = ~p(air) + p(more5degree) + p(Sum_Rain)
+ col(year) + ext(year))
```

```
## Fixed terms are "col(year)", "ext(year)", "p(air)", "p(more5degree)",
"p(Sum_Rain)", "psi(Int)" and "p(Int)"
```

```
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
```

[illegible]

```

## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
## Warning in sqrt(diag(vcov(model, ...))): NaNs wurden erzeugt
head(mx2)

## Global model call: colext(psiformula = ~Wasserversorgung +
Schwimmblattpflanzen +
##      Roehrichtguertel + Flaeche, gammaformula = ~year - 1, epsilonformula =
~year -
##      1, pformula = ~air + more5degree + Sum_Rain, data = sample.EK)
## ---
## Model selection table
##      psi(Int) p(Int) psi(Int) p(Int) psi(Wss) col(yer) ext(yer) p(air)
p(mr5)
## 1      1.406 -15.95      1.406 -15.95      +      + 0.1660
0.1152
## 17     1.406 -15.95      1.406 -15.95      +      + 0.1660
0.1152
## 33     1.406 -15.95      1.406 -15.95      +      + 0.1660
0.1152
## 49     1.406 -15.95      1.406 -15.95      +      + 0.1660
0.1152
## 9      7.964 -15.69      7.964 -15.69      +      + 0.1682
0.1132

```

```
## 25      7.964 -15.69      7.964 -15.69      +      +      + 0.1682
0.1132
##      p(Sum_Rain) df      logLik      AIC delta weight
## 1      0.1287 15 -298.091 626.2 0.00 0.175
## 17      0.1287 15 -298.091 626.2 0.00 0.175
## 33      0.1287 15 -298.091 626.2 0.00 0.175
## 49      0.1287 15 -298.091 626.2 0.00 0.175
## 9      0.1259 17 -296.251 626.5 0.32 0.149
## 25      0.1259 17 -296.251 626.5 0.32 0.149
## Models ranked by AIC(x)
```

Die initiale Vorkommenswahrscheinlichkeit kann durch keinen Parameter umfassend erklärt werden. Lediglich die Wasserversorgung scheint einen Einfluss zu haben.

```
get.models(mx2, subset=5)
```

```
## $`9`
##
## Call:
## colext(psiformula = ~Wasserversorgung + 1, gammaformula = ~0 +
##      year, epsilonformula = ~0 + year, pformula = ~1 + air + more5degree +
##      Sum_Rain, data = sample.EK)
##
## Initial:
##
##              Estimate      SE      z P(>|z|)
## (Intercept)      7.96 26.0 0.3068 0.759
## Wasserversorgungindirekt -7.22 26.0 -0.2781 0.781
## Wasserversorgungkeine 1.81 98.2 0.0184 0.985
##
## Colonization:
##              Estimate      SE      z P(>|z|)
## year2013      1.11 1.22 0.9104 0.363
## year2014     -9.79 120.73 -0.0811 0.935
## year2015      0.00 153.10 0.0000 1.000
## year2016      0.00 162.44 0.0000 1.000
## year2017      2.84 82.03 0.0346 0.972
##
## Extinction:
##              Estimate      SE      z P(>|z|)
## year2013     -2.13 0.665 -3.2033 0.00136
## year2014     -8.19 44.845 -0.1827 0.85502
## year2015      0.00 153.103 0.0000 1.00000
## year2016      0.00 162.435 0.0000 1.00000
## year2017     -2.84 82.034 -0.0346 0.97239
##
## Detection:
##              Estimate      SE      z P(>|z|)
## (Intercept) -15.693 3.1344 -5.01 5.54e-07
## air          0.168 0.0309 5.44 5.19e-08
## more5degree  0.113 0.0264 4.28 1.85e-05
## Sum_Rain     0.126 0.0282 4.46 8.19e-06
##
```

```
## AIC: 626.5029
##
## attr("rank")
## function (x)
## do.call("rank", list(x))
## <environment: 0x000001a4a23815f8>
## attr("call")
## AIC(x)
## attr("class")
## [1] "function"      "rankFunction"
## attr("beta")
## [1] "none"
```

Auch das wollen wir wieder vorhersagen und grafisch darstellen:

```
fmx2.fin <- colext(~ Wasserversorgung, ~year-1, ~year-1, ~ air + Sum_Rain +
more5degree, data = sample.EK)
```

```
# nur Lufttemperatur wechselt
```

```
nd3 <- data.frame(air = mean(air, na.rm=TRUE),
                  more5degree = mean(more5degree),
                  Sum_Rain = mean(Sum_Rain),
                  Wasserversorgung= c("direkt", "indirekt", "keine"))
```

```
det.3 <- round(predict(fmx2.fin, type="psi" , newdata=nd3, appedData = TRUE
),2)
det.3
```

```
## Predicted SE lower upper
## 1 1.00 0.01 0.00 1.00
## 2 0.68 0.14 0.38 0.88
## 3 1.00 0.01 0.00 1.00
```

```
df.det3 <- as.data.frame(cbind(nd3,det.3))
head(df.det3)
```

```
## air more5degree Sum_Rain Wasserversorgung Predicted SE lower
upper
## 1 10.54167 48 81.71667 direkt 1.00 0.01 0.00
1.00
## 2 10.54167 48 81.71667 indirekt 0.68 0.14 0.38
0.88
## 3 10.54167 48 81.71667 keine 1.00 0.01 0.00
1.00
```

```
ggplot(data = df.det3, aes(x = Wasserversorgung, y = Predicted)) +
  geom_boxplot(size=2) +
  geom_errorbar(aes(ymin=lower,ymax=upper),linetype = 1,width = 0.5) +
  labs(x = "Wasserversorgung", y = "Belegungswahrscheinlichkeit") +
  theme_classic()
```

