

# Beispiel 4.2 Multi-Season Modell zur Abhängigkeit der Nachweis- und Vorkommenswahrscheinlichkeit von Erdkröten (*Bufo bufo*) in einer Auenlandschaft von Umweltparametern

Kapitel 4.1 aus Henle, K., A. Grimm-Seyfarth & B. Gruber: Erfassung und Analyse von Tierpopulationen. Ulmer Verlag

Annegret Grimm-Seyfarth

2023-05-16

Dieses Beispiel verwendet das R-Paket “unmarked” (Fiske & Chandler 2011, Kellner et al. 2023) für eine Demonstration, wie die Belegungswahrscheinlichkeit über mehrere Jahre nach MacKenzie et al. (2018) berechnet werden kann. Man nennt dies Multi-Season Occupancy Analysen.

## Multi-Season Occupancy mittels Paket unmarked

Als erstes muss das unmarked package geladen werden. Der folgende Code, schaut nach, ob es nicht schon installiert ist und installiert es gegebenenfalls. Wie laden, neben unmarked, Paket ggplot2 (Wickham 2016) zur Erstellung von Grafiken sowie Paket MuMIn (Barton 2024) zur Modellselektion.

```
# check.packages function: install and load multiple R packages.
# Function from: https://gist.github.com/smithdanielle/9913897
check.packages <- function(pkg){
  new.pkg <- pkg[!(pkg %in% installed.packages()[, "Package"])]
  if (length(new.pkg))
    install.packages(new.pkg, dependencies = TRUE)
  sapply(pkg, require, character.only = TRUE)
}

# benoetigte R pakete
pakete <- c("unmarked", "ggplot2", "MuMIn")

# Pruefe und installiere
check.packages(pakete)
```

```
## unmarked  ggplot2    MuMIn
##      TRUE      TRUE      TRUE
```

Für dieses Beispiel verwenden wir Daten von Erdkröten (*Bufo bufo*) in einer Auenlandschaft. Wir wollen die Vorkommenswahrscheinlichkeit in Abhängigkeit von Umweltparametern berechnen. Die Laichzeit stellt für Amphibien in Deutschland eine optimale Zeit für Bestandserhebungen dar. In einem standardisierten Verfahren wurden alle Amphibien an allen Gewässern im Naturschutzgebiet der Papitzer Lehmflächen bei Leipzig mittels akustischer und visueller Verfahren erhoben. Jede Art wurde zu ihrem jeweiligen Laichzeitraum in

den Jahren 2013, 2014, 2015 und 2018 erfasst. Wir wollen die Analysen hier am Beispiel der Erdkröte darstellen. Es fanden 2013 6, 2014 7, 2015 5 und 2018 ebenfalls 5 Begehungen statt. Um einen Vergleich über die Jahre möglich zu machen, wird eine Nachweisgeschichte mit je 7 Erfassungen pro Jahr (= Saison) erstellt, wobei nicht begangene Tage oder Gewässer pro Saison, inkl. der nicht begangenen Tage in 2016 und 2017, mit „NA“ gekennzeichnet wurden, um sie von einer tatsächlichen Nicht-Beobachtung (0) unterscheiden zu können. Eine Reihe an Erfassungs- (z.B. Wetter) und Standortparametern (z.B. Habitatparameter) wurden parallel und über alle Jahre identisch erfasst.

```
#fn <- system.file('extdata','Erdkroete_JV.csv', package = "UlmerBuch")
# 35 Gewässer mit 7 Besuchen pro Gewässer und Jahr ueber 6 Jahre
#EK <- read.csv2(fn, row.names = "Pond")
EK <- read.csv2("extdata/Erdkroete_JV.csv",
               row.names = "Pond", stringsAsFactors = TRUE)
```

## Multi-Season Basismodell: Erdkröten an/abwesend

```
dim(EK)  #
```

```
## [1] 35 152
```

```
# 35 Gewässer, 152 Spalten
```

```
## Artbeobachtungen
head(EK[,1:42])
```

```
##      S1_13 S2_13 S3_13 S4_13 S5_13 S6_13 S7_13 S1_14 S2_14 S3_14 S4_14 S5_14
## 1      NA      1      NA      1      NA      1      0      1      0      0      0      0
## 2      1      NA      NA      1      NA      1      NA      1      1      1      1      0
## 3      NA      0      0      0      NA      0      0      1      0      0      0      0
## 3b     1      NA      NA      1      NA      0      NA      1      1      0      0      0
## 4      NA      1      NA      NA      NA      1      NA      1      0      0      0      0
## 5      NA      1      NA      NA      NA      1      NA      1      0      0      0      0
##      S6_14 S7_14 S1_15 S2_15 S3_15 S4_15 S5_15 S6_15 S7_15 S1_16 S2_16 S3_16
## 1      0      0      1      1      0      0      0      NA      NA      NA      NA      NA
## 2      1      1      0      1      0      0      1      NA      NA      NA      NA      NA
## 3      0      0      0      0      0      0      0      NA      NA      NA      NA      NA
## 3b     0      1      0      0      0      0      1      NA      NA      NA      NA      NA
## 4      1      0      0      0      0      0      0      NA      NA      NA      NA      NA
## 5      1      0      0      0      0      0      0      NA      NA      NA      NA      NA
##      S4_16 S5_16 S6_16 S7_16 S1_17 S2_17 S3_17 S4_17 S5_17 S6_17 S7_17 S1_18
## 1      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      1
## 2      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      1
## 3      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      0
## 3b     NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      1
## 4      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      1
## 5      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      1
##      S2_18 S3_18 S4_18 S5_18 S6_18 S7_18
## 1      1      1      1      0      NA      NA
## 2      1      1      1      1      NA      NA
## 3      0      1      0      0      NA      NA
## 3b     1      1      1      1      NA      NA
```

```
## 4      1      1      1      0      NA      NA
## 5      1      1      1      1      NA      NA
```

## Spalten S1\_13 (Survey 1, Jahr 2013) bis S7\_18 (Survey 7, Jahr 2018)

## Tagesspezifische Parameter (= obsCovs) sind folgende:

```
head(EK[,43:126])
```

```
##      B1_13 B2_13 B3_13 B4_13 B5_13 B6_13 B7_13 B1_14 B2_14 B3_14 B4_14 B5_14
## 1      NA      2      NA      2      NA      3      2      2      2      2      2      2
## 2      1      NA      NA      2      NA      3      NA      2      2      2      2      2
## 3      NA      2      2      2      NA      3      2      2      2      2      2      2
## 3b     1      NA      NA      2      NA      3      NA      2      2      2      2      2
## 4      NA      2      NA      NA      NA      3      NA      2      2      2      2      2
## 5      NA      2      NA      NA      NA      3      NA      2      2      2      2      2
##      B6_14 B7_14 B1_15 B2_15 B3_15 B4_15 B5_15 B6_15 B7_15 B1_16 B2_16 B3_16
## 1      2      2      2      3      2      2      2      2      2      NA      NA      NA
## 2      2      2      2      3      2      2      2      2      2      NA      NA      NA
## 3      2      2      2      3      2      2      2      2      2      NA      NA      NA
## 3b     2      2      2      3      2      2      2      2      2      NA      NA      NA
## 4      2      2      2      3      2      2      2      2      2      NA      NA      NA
## 5      2      2      2      3      2      2      2      2      2      NA      NA      NA
##      B4_16 B5_16 B6_16 B7_16 B1_17 B2_17 B3_17 B4_17 B5_17 B6_17 B7_17 S1_18.1
## 1      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      2
## 2      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      2
## 3      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      2
## 3b     NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      2
## 4      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      2
## 5      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      NA      2
##      B2_18 B3_18 B4_18 B5_18 B6_18 B7_18 LTemp1_13 LTemp2_13 LTemp3_13 LTemp4_13
## 1      3      1      1      1      NA      NA      9.2      11.7      16.5      15.7
## 2      3      1      1      1      NA      NA      9.2      11.7      16.5      15.7
## 3      3      1      1      1      NA      NA      9.2      11.7      16.5      15.7
## 3b     3      1      1      1      NA      NA      9.2      11.7      16.5      15.7
## 4      3      1      1      1      NA      NA      9.2      11.7      16.5      15.7
## 5      3      1      1      1      NA      NA      9.2      11.7      16.5      15.7
##      LTemp5_13 LTemp6_13 LTemp7_13 LTemp1_14 LTemp2_14 LTemp3_14 LTemp4_14
## 1      16.8      16.1      16.9      14.8      6.4      4.6      5.4
## 2      16.8      16.1      16.9      14.8      6.4      4.6      5.4
## 3      16.8      16.1      16.9      14.8      6.4      4.6      5.4
## 3b     16.8      16.1      16.9      14.8      6.4      4.6      5.4
## 4      16.8      16.1      16.9      14.8      6.4      4.6      5.4
## 5      16.8      16.1      16.9      14.8      6.4      4.6      5.4
##      LTemp5_14 LTemp6_14 LTemp7_14 LTemp1_15 LTemp2_15 LTemp3_15 LTemp4_15
## 1      6.5      9.5      10.9      7.2      6.7      3.6      4.6
## 2      6.5      9.5      10.9      7.2      6.7      3.6      4.6
## 3      6.5      9.5      10.9      7.2      6.7      3.6      4.6
## 3b     6.5      9.5      10.9      7.2      6.7      3.6      4.6
## 4      6.5      9.5      10.9      7.2      6.7      3.6      4.6
## 5      6.5      9.5      10.9      7.2      6.7      3.6      4.6
##      LTemp5_15 LTemp6_15 LTemp7_15 LTemp1_16 LTemp2_16 LTemp3_16 LTemp4_16
## 1      13.8      NA      NA      NA      NA      NA      NA
## 2      13.8      NA      NA      NA      NA      NA      NA
## 3      13.8      NA      NA      NA      NA      NA      NA
```

```

## 3b      13.8      NA      NA      NA      NA      NA      NA
## 4       13.8      NA      NA      NA      NA      NA      NA
## 5       13.8      NA      NA      NA      NA      NA      NA
##      LTemp5_16 LTemp6_16 LTemp7_16 LTemp1_17 LTemp2_17 LTemp3_17 LTemp4_17
## 1       NA      NA      NA      NA      NA      NA      NA
## 2       NA      NA      NA      NA      NA      NA      NA
## 3       NA      NA      NA      NA      NA      NA      NA
## 3b      NA      NA      NA      NA      NA      NA      NA
## 4       NA      NA      NA      NA      NA      NA      NA
## 5       NA      NA      NA      NA      NA      NA      NA
##      LTemp5_17 LTemp6_17 LTemp7_17 LTemp1_18 LTemp2_18 LTemp3_18 LTemp4_18
## 1       NA      NA      NA      14.1      9.5      5.9      11.8
## 2       NA      NA      NA      14.1      9.5      5.9      11.8
## 3       NA      NA      NA      14.1      9.5      5.9      11.8
## 3b      NA      NA      NA      14.1      9.5      5.9      11.8
## 4       NA      NA      NA      14.1      9.5      5.9      11.8
## 5       NA      NA      NA      14.1      9.5      5.9      11.8
##      LTemp5_18 LTemp6_18 LTemp7_18
## 1      14.8      NA      NA
## 2      14.8      NA      NA
## 3      14.8      NA      NA
## 3b     14.8      NA      NA
## 4      14.8      NA      NA
## 5      14.8      NA      NA

```

```

# Spalten B1_13 (Beschattung zu Survey 1, Jahr 2013)
# bis B7_18 (Beschattung zu Survey 7, Jahr 2018)
# Spalten LTemp1_13 (Lufttemperatur zu Survey 1, Jahr 2013)
# bis LTemp7_18 (Lufttemperatur zu Survey 7, Jahr 2018)

```

```

## Jahresspezifische Plotparameter (= yearlySiteCovs) sind folgende:
head(EK[,127:150])

```

```

##      Roehrichtguertel_13 Roehrichtguertel_14 Roehrichtguertel_15
## 1           0.50           0.75           0.05
## 2           0.50           0.50           0.05
## 3           0.05           0.75           0.05
## 3b          0.05           0.05           0.05
## 4           0.50           0.75           0.05
## 5           0.50           0.75           0.50
##      Roehrichtguertel_16 Roehrichtguertel_17 Roehrichtguertel_18
## 1           0.5           0.5           0.05
## 2           0.5           0.5           0.50
## 3           0.5           0.5           0.05
## 3b          0.5           0.5           0.05
## 4           0.5           0.5           0.05
## 5           0.5           0.5           0.50
##      Schwimmblattpflanzen_13 Schwimmblattpflanzen_14 Schwimmblattpflanzen_15
## 1           0.5           0.75           0.50
## 2           0.5           0.50           0.50
## 3           0.5           0.75           0.75
## 3b          0.5           0.50           0.50
## 4           0.5           0.50           0.50
## 5           0.5           0.50           0.50

```

```
## Schwimmblattpflanzen_16 Schwimmblattpflanzen_17 Schwimmblattpflanzen_18
## 1 0.5 0.5 0.05
## 2 0.5 0.5 0.05
## 3 0.5 0.5 0.50
## 3b 0.5 0.5 0.05
## 4 0.5 0.5 0.05
## 5 0.5 0.5 0.05
## Sum_Rain_13 Sum_Rain_14 Sum_Rain_15 Sum_Rain_16 Sum_Rain_17 Sum_Rain_18
## 1 99.5 45.1 67.7 105 93.4 79.6
## 2 99.5 45.1 67.7 105 93.4 79.6
## 3 99.5 45.1 67.7 105 93.4 79.6
## 3b 99.5 45.1 67.7 105 93.4 79.6
## 4 99.5 45.1 67.7 105 93.4 79.6
## 5 99.5 45.1 67.7 105 93.4 79.6
## Tage_5_Grad_13 Tage_5_Grad_14 Tage_5_Grad_15 Tage_5_Grad_16 Tage_5_Grad_17
## 1 23 74 41 48 63
## 2 23 74 41 48 63
## 3 23 74 41 48 63
## 3b 23 74 41 48 63
## 4 23 74 41 48 63
## 5 23 74 41 48 63
## Tage_5_Grad_18
## 1 39
## 2 39
## 3 39
## 3b 39
## 4 39
## 5 39
```


```
# Roehrichtquertel_13 bis Roehrichtquertel_18
# (Prozentuale Bedeckung der Gewaesser mit Röhrriecht pro Jahr)
# Schwimmblattpflanzen_13 bis Schwimmblattpflanzen_18
# (Prozentuale Bedeckung der Gewässer mit Schwimmblattpflanzen pro Jahr)
# Sum_Rain_13 bis Sum_Rain_18 (Aufsummierter Niederschlag des Frühjahres / Jahr)
# Tage_5_Grad_13 bis Tage_5_Grad_18 (Anzahl Tage ueber 5°C im Frühjahr / Jahr)

## Plotspezifische Parameter (= siteCovs) sind folgende:
head(EK[,151:152])
```

```
## Wasserversorgung Flaeche
## 1 indirekt 3532.35
## 2 direkt 9479.99
## 3 indirekt 712.23
## 3b direkt 1043.63
## 4 direkt 3087.35
## 5 indirekt 23454.20
```

```
# Wasserversorgung
# (direkt gespeist, indirekt durch Druckwasser gespeist, keine Wasserspeisung)
# Flaeche (Wasserflaeche in qm)

# Summierte Anzahl der Erdkroeten-Beobachtungen ueber alle 35 Gewaesser
barplot(table(rowSums(EK[,1:42]), na.rm=TRUE)))
```



### Aufbereiten der Daten in das unmarked format

Wir müssen die Daten noch umformatieren mittels der “unmarkedFrameOccu” Funktion. Dazu definieren wir zunächst die Artbeobachtungsdaten und die einzelnen Parameter.

```
# Artbeobachtungen
y.EK <- EK[,1:42]
y.EK<- as.matrix(y.EK)

# Parameter für den Jahreseffekt (seasonal effect im unmarked frame)
year<- as.character(2013:2018)
years <- matrix(year, nrow(y.EK), 6, byrow=TRUE)

# Parameter pro Survey bzw. pro Jahr als Matrix schreiben
cloud <- as.matrix(EK[,43:84])
air <- as.matrix(EK[,85:126])
Roehrichtguertel <- as.matrix(EK[,127:132])
Schwimmblattpflanzen <- as.matrix(EK[,133:138])
Sum_Rain <- as.matrix(EK[,139:144])
more5degree <- as.matrix(EK[,145:150])

#NA-Werte anpassen
y.EK[is.na(cloud) != is.na(y.EK)] <- NA

### Datensatz umformatieren, wobei numPrimary die Anzahl Primärperioden,
```

```
# also Jahre in unserem Fall, darstellt
sample.EK <- unmarkedMultFrame(y=y.EK,
                                siteCovs= EK[,c(151:152, 127, 133)],
                                yearlySiteCovs=list(year=years,
                                                        Roehrichtguertel= Roehrichtguertel,
                                                        Schwimmblattpflanzen= Schwimmblattpflanzen,
                                                        Sum_Rain = Sum_Rain,
                                                        more5degree=more5degree),
                                obsCovs = list(cloud=cloud, air = air),
                                numPrimary=6)
```

Unmarked hat eine Summary funktion, welche die Daten übersichtlich zusammenfasst

```
summary(sample.EK)
```

```
## unmarkedFrame Object
##
## 35 sites
## Maximum number of observations per site: 42
## Mean number of observations per site: 16.14
## Number of primary survey periods: 6
## Number of secondary survey periods: 7
## Sites with at least one detection: 33
##
## Tabulation of y observations:
##      0      1 <NA>
## 317  248  905
##
## Site-level covariates:
## Wasserversorgung      Flaeche      Roehrichtguertel_13
## direkt   : 4      Min.      : 72.52      Min.      :0.0500
## indirekt:12      1st Qu.: 1476.59      1st Qu.:0.0500
## keine    :19      Median : 3284.48      Median :0.0500
##                      Mean      : 6804.60      Mean      :0.1871
##                      3rd Qu.: 7867.69      3rd Qu.:0.1900
##                      Max.      :40517.50      Max.      :0.7500
## Schwimmblattpflanzen_13
## Min.      :0.0500
## 1st Qu.:0.3900
## Median :0.5000
## Mean      :0.3914
## 3rd Qu.:0.5000
## Max.      :0.5000
##
## Observation-level covariates:
##      cloud      air
## Min.      :1.000      Min.      : 3.600
## 1st Qu.:2.000      1st Qu.: 6.475
## Median :2.000      Median :10.200
## Mean      :1.932      Mean      :10.542
## 3rd Qu.:2.000      3rd Qu.:14.800
## Max.      :3.000      Max.      :16.900
## NA's      :823      NA's      :630
```

```
##
## Yearly-site-level covariates:
##   year   Roehrichtguertel Schwimmblattpflanzen   Sum_Rain
## 2013:35   Min.    :0.0500   Min.    :0.0500       Min.    : 45.10
## 2014:35   1st Qu.:0.0500   1st Qu.:0.5000       1st Qu.: 67.70
## 2015:35   Median :0.5000   Median :0.5000       Median : 86.50
## 2016:35   Mean    :0.3482   Mean    :0.4228       Mean    : 81.72
## 2017:35   3rd Qu.:0.5000   3rd Qu.:0.5000       3rd Qu.: 99.50
## 2018:35   Max.    :0.7500   Max.    :0.7500       Max.    :105.00
## more5degree
## Min.      :23.0
## 1st Qu.:39.0
## Median :44.5
## Mean     :48.0
## 3rd Qu.:63.0
## Max.     :74.0
```

### Einfaches Multi-Season Belegungsmodell ohne Kovariable definieren

```
occu.m1 <- colext(~1, #initiale occupancy [Jahr 1], keine Kovariable
                  ~year-1, #colonization, keine Kovariable aber jahresabhängig
                  ~year-1, #extinction, keine Kovariable aber jahresabhängig
                  ~year #detection, keine Kovariable aber jahresabhängig
                  , data = sample.EK)
```

Die normale Zusammenfassung zeigt die Schätzungen auf der logit-scale, was nicht allzusehr weiterhilft.

```
summary(occu.m1)
```

```
##
## Call:
## colext(psiformula = ~1, gammaformula = ~year - 1, epsilonformula = ~year -
##       1, pformula = ~year, data = sample.EK)
##
## Initial (logit-scale):
##   Estimate      SE      z P(>|z|)
##      1.35 0.575 2.35   0.019
##
## Colonization (logit-scale):
##           Estimate      SE      z P(>|z|)
## year2013  9.23e-01   1.11  8.32e-01  0.405
## year2014 -6.37e+00  31.51 -2.02e-01  0.840
## year2015  0.00e+00 112.38  0.00e+00  1.000
## year2016  1.53e-10 114.40  1.34e-12  1.000
## year2017  2.24e+00  66.76  3.36e-02  0.973
##
## Extinction (logit-scale):
##           Estimate      SE      z P(>|z|)
## year2013 -2.51e+00   1.05 -2.38e+00  0.0171
## year2014 -9.22e+00  52.74 -1.75e-01  0.8612
## year2015  0.00e+00 112.38  0.00e+00  1.0000
```



```
## year2016 -1.53e-10 114.40 -1.34e-12 1.0000
## year2017 -2.24e+00 66.76 -3.36e-02 0.9732
##
## Detection (logit-scale):
##      Estimate      SE      z  P(>|z|)
## (Intercept)   1.594   0.561   2.84 4.50e-03
## year2014     -1.838   0.583  -3.15 1.61e-03
## year2015     -2.842   0.609  -4.67 3.05e-06
## year2016      0.000 112.379   0.00 1.00e+00
## year2017      0.000 112.379   0.00 1.00e+00
## year2018     -0.949   0.592  -1.60 1.09e-01
##
## AIC: 659.9695
## Number of sites: 35
```

Die Estimates sind auf der logit Skala und daher für uns nicht interpretierbar. Mittels der “predict” function können wir aber die Belegung in Anwesend/Abwesend umwandeln. Hier steht *psi* fuer die Occupancy.

```
predict(occu.m1, newdata = data.frame(year = 2013), type = "psi")
```

```
## Predicted      SE      lower      upper
## 1 0.7940551 0.09407504 0.5552813 0.9225176
```

Als erstes Ergebniss erfahren wir, dass initial etwa 79% aller Gewaesser besetzt waren.

Weiterhin möchten wir noch die Nachweiswahrscheinlichkeit *p* schätzen. Da wir in unserem Modell die Nachweiswahrscheinlichkeit als konstant für alle Sites, lediglich variabel zwischen den Jahren angenommen haben, ist es egal, für welche Site wir die Nachweiswahrscheinlichkeit schätzen lassen. Hier steht *det* für die Nachweiswahrscheinlichkeit.

```
predict(occu.m1, newdata = data.frame(year = as.factor(2013:2018)),
       type = "det")
```

```
## Predicted      SE      lower      upper
## 1 0.8311125 0.07873681 6.210718e-01 0.9366102
## 2 0.4392155 0.03882327 3.651035e-01 0.5161414
## 3 0.2229362 0.04104244 1.527769e-01 0.3133964
## 4 0.8311125 15.77419211 1.081116e-95 1.0000000
## 5 0.8311125 15.77419211 1.081116e-95 1.0000000
## 6 0.6558348 0.04289424 5.676628e-01 0.7344370
```

Wir sehen, dass die Nachweiswahrscheinlichkeit *p* von 2013 bis 2015 von 83,11% auf 22,29% abgenommen hat, 2016 und 2017 nimmt sie, aufgrund fehlender Beobachtungsdaten, die initiale Nachweiswahrscheinlichkeit an und 2018 ist diese im Vergleich zu 2014 und 2015 wieder gestiegen (65,58%).

Nun können wir uns auch die Extinktion (*ext*) und Kolonisierung (*col*) anschauen. Da beide Prozesse nur zwischen den Jahren stattfinden können, lassen wir das Endjahr jeweils aus.

```
predict(occu.m1, newdata = data.frame(year = as.factor(2013:2017)),
       type = "ext")
```

```
## Predicted      SE      lower      upper
```

```
## 1 0.0750294763 0.073094921 1.018912e-02 0.3899391
## 2 0.0000989502 0.005217818 1.275438e-49 1.0000000
## 3 0.5000000000 28.094697159 2.202935e-96 1.0000000
## 4 0.5000000000 28.600493421 4.176990e-98 1.0000000
## 5 0.0961416394 5.800994942 1.599428e-58 1.0000000
```

```
predict(occu.m1, newdata = data.frame(year = as.factor(2013:2017)),
       type = "col")
```

```
##      Predicted      SE      lower      upper
## 1 0.715655037 0.22566015 2.226205e-01 0.9567473
## 2 0.001709714 0.05377684 2.596391e-30 1.0000000
## 3 0.500000000 28.09469716 2.202935e-96 1.0000000
## 4 0.500000000 28.60049342 4.176990e-98 1.0000000
## 5 0.903858361 5.80099494 1.413651e-56 1.0000000
```

Wir sehen, dass die Kolonisierung von 2013-2014 bei 71% lag, dann stark abnahm und von 2017-2018 wieder sehr stark zunahm.

Schätzungen der Belegungswahrscheinlichkeit (Occupancy) in den Folgejahren müssen aus den Schätzungen der Belegung im ersten Jahr und den beiden Parametern, die die Dynamik bestimmen, Extinktion und Kolonisierung, abgeleitet werden. *unmarked* kennt zwei Wege dies zu tun.

```
projected(occu.m1)
```

```
##           1           2           3  4  5           6
## unoccupied 0.2059449 0.1181369 0.1180222 0.5 0.5 0.09614164
## occupied   0.7940551 0.8818631 0.8819778 0.5 0.5 0.90385836
```

Dieser Datensatz enthält einen Array mit 35 Datenframes, je eins pro Gewässer. Jeder Datenframe enthält die abgeleitete Schätzung von Abwesenheit und Belegung (Zeilen) pro Jahr (Spalten). Da wir hier keinen Unterschied pro Gewässer berücksichtigen, sind alle 35 Datenframes identisch - es wird daher nur eine Gesamtschätzung angezeigt. Die Jahre ohne Artdaten wurden von *unmarked* auf 50% gesetzt.

```
smoothed(occu.m1)
```

```
##           1           2           3  4  5           6
## unoccupied 0.2059458 0.1183946 0.1180385 0.5 0.5 0.09613875
## occupied   0.7940542 0.8816054 0.8819615 0.5 0.5 0.90386125
```

Im Gegensatz zu *projected* bekommt man mit *smoothed* einen Rückschluss auf den Anteil der belegten Standorte und nicht auf die Gesamtpopulation der Standorte. Somit handelt es sich bei den *projected* Werten um Schätzungen der Populationsparameter und bei den *smoothed* Schätzungen um die Mengen endlicher Stichproben. Mit anderen Worten: Unser geglätteter Schätzer (*smoothed*) ( $\Psi_i|Y$ , wobei  $\Psi_i$  die jährliche Schätzung der Vorkommenswahrscheinlichkeit und  $Y$  die Beobachtungsdaten darstellt) schätzt den Anteil der Stichprobenorte, die in jedem Jahr besetzt sind, während der projektionsbasierte Schätzer (*projected*) ( $\Psi_i$ ) die Belegungsrate für die gesamte Population der hypothetischen Standorte, aus denen unsere Stichprobe ausgewählt wurde, schätzt (Weir et al. 2009).

Mithilfe der Bootstrap Methode bekommt man zu diesen Schätzungen auch Standardfehler.

```
occu.m1 <- nonparboot(occu.m1, B = 10)
# fuer gute Schätzungen sollte man B deutlich höher setzen,
# was aber eine höhere Berechnungszeit zur Folge hat
cbind(smoothed=smoothed(occu.m1)[2,], SE=occu.m1@smoothed.mean.bsse[2,])
```

```
##      smoothed      SE
## 1 0.7940542 5.968823e-02
## 2 0.8816054 7.984313e-02
## 3 0.8819615 9.087383e-02
## 4 0.5000000 0.000000e+00
## 5 0.5000000 3.812863e-11
## 6 0.9038612 7.079728e-02
```

Nun haben wir für jedes Jahr eine Schätzung der Vorkommenwahrscheinlichkeit und deren Standardfehler, aus dem man wiederum ein Konfidenzintervall berechnen könnte.

## Multi-Season Occupancy Modell mit Kovariablen

Unser Erdkrötendatensatz war bereits für die Berechnung mit Kovariablen formatiert. Nun kann man mittels Modellvergleiche herausfinden, welche der Kovariablen tatsächlich einen Einfluss auf Nachweis- und Vorkommenswahrscheinlichkeit haben.

### Nachweiswahrscheinlichkeit

Wir beginnen hierzu mit der Nachweiswahrscheinlichkeit. Wir nehmen an, dass diese von Bedeckung, Lufttemperatur, Niederschlag und der Anzahl Tage über 5 Grad Celsius abhängen könnte (bezogen auf die Aktivität von Erdkröten). Zusätzlich nehmen wir an, dass alle Schätzwerte sich zwischen den Jahren unterscheiden, was nicht unbedingt durch die aufgenommenen Parameter erklärt werden kann.

```
fm1 <- colext(~ 1, ~year-1, ~year-1, ~cloud + air + Sum_Rain + more5degree,
             data = sample.EK)

summary(fm1)
```

```
##
## Call:
## colext(psiformula = ~1, gammaformula = ~year - 1, epsilonformula = ~year -
##      1, pformula = ~cloud + air + Sum_Rain + more5degree, data = sample.EK)
##
## Initial (logit-scale):
##      Estimate      SE      z P(>|z|)
##      1.41 0.572 2.46 0.0138
##
## Colonization (logit-scale):
##      Estimate      SE      z P(>|z|)
## year2013    0.846    1.1 0.771 0.441
## year2014   -5.731   22.8 -0.251 0.802
## year2015    0.000 143.6 0.000 1.000
## year2016    0.000 159.4 0.000 1.000
## year2017    2.775 198.3 0.014 0.989
##
```

```
## Extinction (logit-scale):
##      Estimate      SE      z P(>|z|)
## year2013     -2.48   1.0 -2.470  0.0135
## year2014     -9.81  85.1 -0.115  0.9082
## year2015      0.00 143.6  0.000  1.0000
## year2016      0.00 159.4  0.000  1.0000
## year2017     -2.78 198.3 -0.014  0.9888
##
## Detection (logit-scale):
##      Estimate      SE      z P(>|z|)
## (Intercept) -16.4741 3.4733 -4.743 2.11e-06
## cloud        0.0734 0.1913  0.383 7.01e-01
## air          0.1660 0.0310  5.358 8.41e-08
## Sum_Rain     0.1323 0.0304  4.349 1.37e-05
## more5degree  0.1181 0.0279  4.238 2.25e-05
##
## AIC: 628.0396
## Number of sites: 35
```

```
# prüfen wir noch auf Kollinearität
# (Korrelation der Parameter untereinander)
vif(fmx1, type = "det")
```

```
##      cloud      air      Sum_Rain more5degree
##      1.142614    1.144522    21.786194    20.626669
```

```
# Sum_Rain und more5degree haben Werte größer 5
# entfernen wir zunächst den Temperaturwert, da dieser sicher mit air korreliert
fmx1 <- colext(~ 1, ~year-1, ~year-1, ~cloud + air + Sum_Rain,
              data = sample.EK)
vif(fmx1, type = "det")
```

```
##      cloud      air Sum_Rain
##      1.045787  1.090955  1.122332
```

```
# nun sind alle Werte kleiner als 5, keine Kollinearität

# Modellselektion mithilfe von dredge aus dem MuMIn package
mx1<-dredge(fmx1, rank="AIC", fixed =~col(year) +ext(year) )
# Das braucht aufgrund von der Berechnung aller Modellkombinationen etwas Zeit.
head(mx1)
```

```
## Global model call: colext(psiformula = ~1, gammaformula = ~year - 1, epsilonformula = ~year -
##      1, pformula = ~cloud + air + Sum_Rain, data = sample.EK)
## ---
## Model selection table
##      psi(Int) col(yer) ext(yer) p(Int) p(air)      p(cld) p(Sum_Ran) df      logLik
## 6      1.587      +      + -2.448 0.1964      0.009697 14 -304.462
## 2      1.725      +      + -1.952 0.2098      13 -305.571
## 4      1.718      +      + -1.674 0.2069 -0.13230      14 -305.272
## 8      1.585      +      + -2.236 0.1955 -0.08684      15 -304.344
## 5      1.661      +      + -1.521      0.023710 13 -327.763
```

```
## 7      1.644      +      + -1.124      -0.16840      0.022500 14 -327.307
##      AIC delta weight
## 6 636.9  0.00  0.363
## 2 637.1  0.22  0.325
## 4 638.5  1.62  0.161
## 8 638.7  1.76  0.150
## 5 681.5 44.60  0.000
## 7 682.6 45.69  0.000
## Models ranked by AIC(x)
```

Die Parameter fuer die Nachweiswahrscheinlichkeit finden wir in der Modellvergleichstabelle indiziert mit p(). Das beste Modell mit dem geringsten AIC-Wert beinhaltet die Parameter Lufttemperatur und Niederschlagsmenge. Schauen wir uns die Ergebnisse des ersten Modelles einmal an.

```
get.models(mx1, subset=1)
```

```
## $'6'
##
## Call:
## colext(psiformula = ~1, gammaformula = ~1 + year, epsilonformula = ~1 +
##      year, pformula = ~air + Sum_Rain + 1, data = sample.EK)
##
## Initial (logit-scale):
##      Estimate      SE      z P(>|z|)
##      1.59 0.64 2.48 0.0132
##
## Colonization (logit-scale):
##      Estimate      SE      z P(>|z|)
## (Intercept)  0.592  1.17  0.5070  0.612
## year2014     -9.746 83.13 -0.1172  0.907
## year2015     -2.196 38.56 -0.0570  0.955
## year2016     -1.646 35.90 -0.0459  0.963
## year2017      1.080 13.14  0.0822  0.934
##
## Extinction (logit-scale):
##      Estimate      SE      z P(>|z|)
## (Intercept)  -2.56  1.08 -2.3683  0.0179
## year2014      1.16  1.26  0.9183  0.3585
## year2015     -1.75 32.76 -0.0534  0.9574
## year2016     -2.43 40.40 -0.0601  0.9521
## year2017     -3.69 28.15 -0.1310  0.8958
##
## Detection (logit-scale):
##      Estimate      SE      z P(>|z|)
## (Intercept) -2.4477 0.44516 -5.50 3.83e-08
## air          0.1964 0.03011  6.52 6.92e-11
## Sum_Rain      0.0097 0.00663  1.46 1.44e-01
##
## AIC: 636.9245
## Number of sites: 35
##
##
```

```
##
## attr("rank")
## function (x)
## do.call("rank", list(x))
## <environment: 0x000002727ea577d8>
## attr("call")
## AIC(x)
## attr("class")
## [1] "function"      "rankFunction"
## attr("beta")
## [1] "none"
```

Alle beiden Kovariablen beeinflussen die Nachweiswahrscheinlichkeit positiv. Nun schauen wir uns noch an, wie die relative Wichtigkeit der Parameter untereinander aussieht. Dazu lassen wir uns die Summe aller AIC-Wichtungen pro Parameter ausgeben:

```
sw(mx1)
```

```
##               col(year) ext(year) p(air) p(Sum_Rain) p(cloud)
## Sum of weights:   1.00      1.00    1.00   0.51      0.31
## N containing models: 8        8      4      4        4
```

Am wichtigsten erscheint die Lufttemperatur (AIC weight = 1), gefolgt von der Niederschlagsmenge (AIC weight = 0,51). Die Bewölkung spielt für den Nachweis von Erdkröten, zumindest in diesem Gebiet, keine nennenswerte Rolle.

Das können wir nun auf neue Daten projizieren und grafisch darstellen. Starten wir mit der Abhängigkeit von Lufttemperatur:


```
fm1.fin <- colext(~ 1, ~year-1, ~year-1, ~ air + Sum_Rain, data = sample.EK)

# nur Lufttemperatur wechselt
nd1 <- data.frame(air = 3:17,
                  Sum_Rain = mean(Sum_Rain))

det.1 <- round(predict(fm1.fin, type="det", newdata=nd1, appedData = TRUE ),2)
# det.1
df.det1 <- as.data.frame(cbind(nd1,det.1))
head(df.det1)
```

```
##   air Sum_Rain Predicted   SE lower upper
## 1   3 81.71667    0.26 0.05  0.17  0.37
## 2   4 81.71667    0.30 0.05  0.20  0.41
## 3   5 81.71667    0.34 0.05  0.25  0.44
## 4   6 81.71667    0.38 0.05  0.29  0.48
## 5   7 81.71667    0.43 0.05  0.34  0.52
## 6   8 81.71667    0.48 0.04  0.39  0.57
```

```
ggplot(data = df.det1, aes(x = air, y = Predicted)) +
  geom_ribbon(aes(ymin = lower, ymax = upper), fill = "gray") +
  stat_smooth(method = "loess", col = "black", se = FALSE) +
  labs(x = "Lufttemperatur [°C]", y = "Nachweiswahrscheinlichkeit") +
  theme_classic()
```



Die Nachweiswahrscheinlichkeit steigt mit der Lufttemperatur stark an.

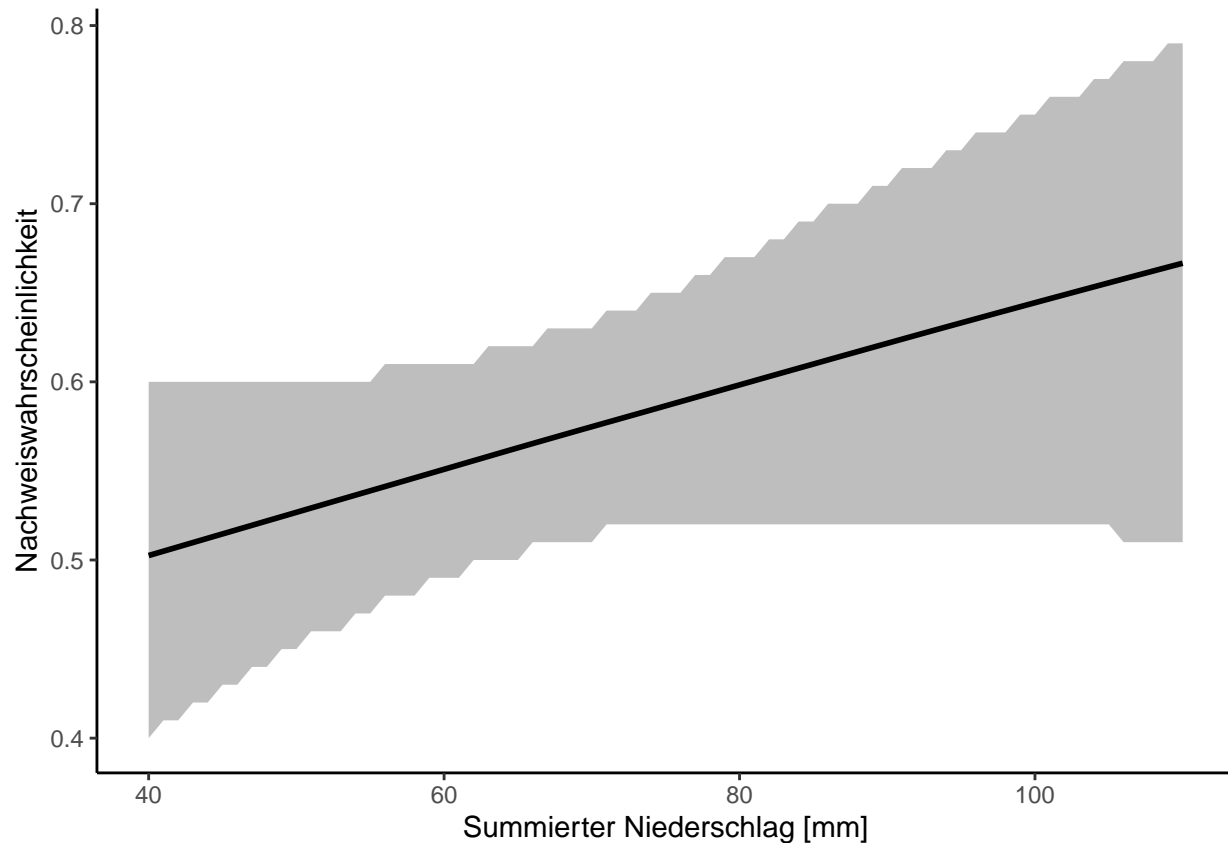
Schauen wir uns noch die Abhängigkeit von Niederschlag an:

```
# nur Niederschlag wechselt
nd2 <- data.frame(air = mean(air, na.rm=TRUE),
                  Sum_Rain = 40:110)

det.2 <- round(predict(fmx1.fin, type="det", newdata=nd2, appedData = TRUE ),2)
df.det2 <- as.data.frame(cbind(nd2,det.2))
head(df.det2)
```

```
##      air Sum_Rain Predicted   SE lower upper
## 1 10.54167     40      0.50 0.05  0.40  0.6
## 2 10.54167     41      0.51 0.05  0.41  0.6
## 3 10.54167     42      0.51 0.05  0.41  0.6
## 4 10.54167     43      0.51 0.05  0.42  0.6
## 5 10.54167     44      0.51 0.05  0.42  0.6
## 6 10.54167     45      0.51 0.04  0.43  0.6
```

```
ggplot(data = df.det2, aes(x = Sum_Rain, y = Predicted)) +
  geom_ribbon(aes(ymin = lower, ymax = upper), fill = "gray") +
  stat_smooth(method = "loess", col = "black", se = FALSE) +
  labs(x = "Summierter Niederschlag [mm]", y = "Nachweiswahrscheinlichkeit") +
  theme_classic()
```



Auch der Niederschlag beeinflusst die Nachweiswahrscheinlichkeit positiv.

### Vorkommenswahrscheinlichkeit

Als nächstes schauen wir uns an, welche Parameter die Vorkommenswahrscheinlichkeit von Erdkröten beeinflusst. Da diese nur den ersten Wert schätzt (initiale Occupancy), sind auch nur die Parameter des ersten Werts (2013) nötig.

```
fm2 <- colext(~ Wasserversorgung + Schwimmblattpflanzen_13 +
  Roehrichtguertel_13 + Flaeche,
  ~year-1, ~year-1,
  ~ air + Sum_Rain,
  data = sample.EK)
```

```
# wir prüfen zunächst wieder die Kollinearität
vif(fm2, type="psi")
```

```
## Wasserversorgungindirekt    Wasserversorgungkeine  Schwimmblattpflanzen_13
##           1.00000004          0.12569120          0.86716453
##      Roehrichtguertel_13          Flaeche
##           0.96840634          -0.03873085
```

```
# Alle Werte < 5 - keine Kollinearität
```

```
# Modellselektion
```



```

# alle bekannten Parameter bleiben gleich
# auch das braucht einiges an Computerzeit
mx2<-dredge(fmx2, rank="AIC", fixed = ~p(air) + p(Sum_Rain) +
           col(year) + ext(year))
head(mx2)

## Global model call: colext(psiformula = ~Wasserversorgung + Schwimmblattpflanzen_13 +
##   Roehrichtguertel_13 + Flaeche, gammaformula = ~year - 1,
##   epsilonformula = ~year - 1, pformula = ~air + Sum_Rain, data = sample.EK)
## ---
## Model selection table
##   psi(Int) psi(Rhr_13) psi(Sch_13) psi(Wss) col(yer) ext(yer) p(Int) p(air)
## 11   8.5170    14.990              +        +        + -2.484 0.1986
##  3   0.6784     8.167              +        +        + -2.489 0.1970
##  1   1.5870              +        +        + -2.448 0.1964
##  9   8.6670              +        +        + -2.469 0.1983
## 15  10.1900    19.310    -4.0050      +        +        + -2.474 0.1983
##  7   0.9981     8.261    -0.7875              +        + -2.487 0.1969
##   p(Sum_Ran) df   logLik   AIC delta weight
## 11   0.010030 17 -301.193 636.4  0.00  0.220
##  3   0.010360 15 -303.201 636.4  0.02  0.218
##  1   0.009697 14 -304.462 636.9  0.54  0.168
##  9   0.009807 16 -302.528 637.1  0.67  0.157
## 15   0.009911 18 -300.541 637.1  0.70  0.155
##  7   0.010350 16 -303.175 638.4  1.97  0.082
## Models ranked by AIC(x)

```

Die initiale Vorkommenswahrscheinlichkeit kann durch die Röhrichtpflanzen und die Wasserversorgung erklärt werden, wobei die Differenz zum Null-Modell extrem gering ist. Schwimmblattpflanzen könnten auch einen Einfluss haben, die Fläche jedoch scheint keinen Einfluss zu haben.

```

get.models(mx2, subset = 5)

## $'15'
##
## Call:
## colext(psiformula = ~Roehrichtguertel_13 + Schwimmblattpflanzen_13 +
##   Wasserversorgung + 1, gammaformula = ~1 + year, epsilonformula = ~1 +
##   year, pformula = ~1 + air + Sum_Rain, data = sample.EK)
##
## Initial (logit-scale):
##               Estimate      SE        z P(>|z|)
## (Intercept)      10.192 58.31  0.17478  0.861
## Roehrichtguertel_13 19.308 78.28  0.24666  0.805
## Schwimmblattpflanzen_13 -4.005  3.96 -1.01101  0.312
## Wasserversorgungindirekt -9.513 58.52 -0.16257  0.871
## Wasserversorgungkeine  0.742 87.15  0.00852  0.993

## Colonization (logit-scale):
##               Estimate      SE        z P(>|z|)
## (Intercept)      1.045  1.23  0.8494  0.396
## year2014     -10.664 97.55 -0.1093  0.913

```

```
## year2015      -3.321 190.91 -0.0174  0.986
## year2016      -2.883   NaN     NaN     NaN
## year2017       0.872   7.68  0.1136  0.910
##
## Extinction (logit-scale):
##           Estimate      SE      z P(>|z|)
## (Intercept)  -2.146  0.692 -3.1034 0.00191
## year2014      0.749  0.948  0.7909 0.42900
## year2015     -2.097 36.454 -0.0575 0.95413
## year2016     -3.479 59.267 -0.0587 0.95319
## year2017     -3.391 17.017 -0.1993 0.84203
##
## Detection (logit-scale):
##           Estimate      SE      z P(>|z|)
## (Intercept) -2.47442 0.43695 -5.66 1.49e-08
## air         0.19833 0.03012  6.58 4.57e-11
## Sum_Rain    0.00991 0.00648  1.53 1.26e-01
##
## AIC: 637.0818
## Number of sites: 35

##
##
## attr("rank")
## function (x)
## do.call("rank", list(x))
## <environment: 0x000002727b07bc88>
## attr("call")
## AIC(x)
## attr("class")
## [1] "function"      "rankFunction"
## attr("beta")
## [1] "none"
```

Schauen wir uns wieder die Parameterwichtung an:

```
sw(mx2)
```

```
##           col(year) ext(year) p(air) p(Sum_Rain)
## Sum of weights:      1      1      1      1
## N containing models: 16      16      16      16
##           psi(Roehrichtguertel_13) psi(Wasserversorgung)
## Sum of weights:      0.6      0.53
## N containing models:  8      8
##           psi(Schwimmblattpflanzen_13) psi(Flaeche)
## Sum of weights:      0.33      <0.01
## N containing models:  8      8
```

In das finale Modell werden daher Röhrichtgürtel und Wasserversorgung aufgenommen, jedoch nicht die anderen Parameter.

Auch das wollen wir wieder vorhersagen und grafisch darstellen:

```

fmx2.fin <- colext(~ Roehrichtguertel_13 + Wasserversorgung,
                  ~year-1, ~year-1,
                  ~ air + Sum_Rain, data = sample.EK)

# nur Wasserversorgung wechselt
nd3 <- expand.grid(air = mean(air, na.rm=TRUE),
                  Sum_Rain = mean(Sum_Rain),
                  Wasserversorgung= c("direkt", "indirekt", "keine"),
                  Roehrichtguertel_13 = 0)

det.3 <- round(predict(fmx2.fin, type="psi" , newdata=nd3, appedData = TRUE ),2)
#det.3
df.det3 <- as.data.frame(cbind(nd3,det.3))
head(df.det3)

```

```

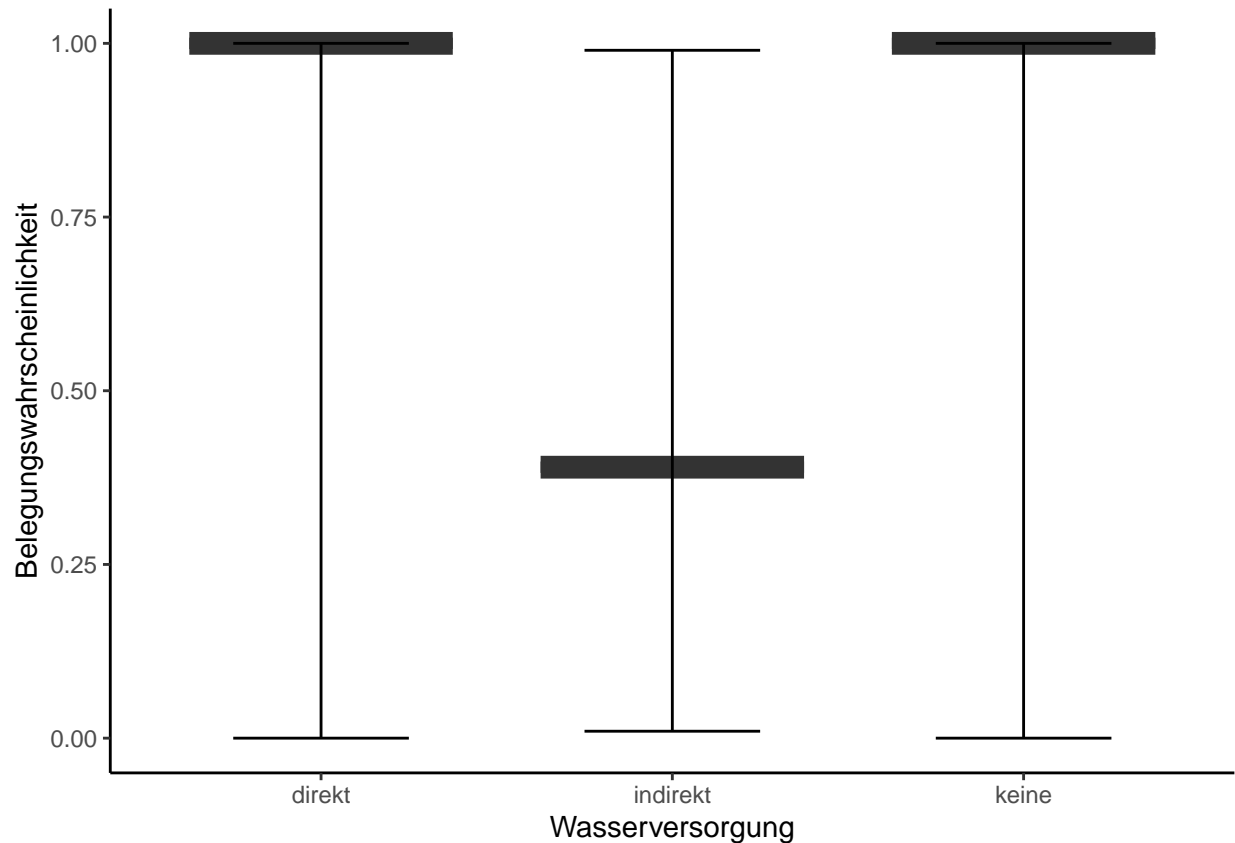
##      air Sum_Rain Wasserversorgung Roehrichtguertel_13 Predicted   SE lower
## 1 10.54167 81.71667      direkt              0      1.00 0.02  0.00
## 2 10.54167 81.71667     indirekt              0      0.39 0.56  0.01
## 3 10.54167 81.71667       keine              0      1.00 0.00  0.00
## upper
## 1  1.00
## 2  0.99
## 3  1.00

```

```

ggplot(data = df.det3, aes(x = Wasserversorgung, y = Predicted)) +
  geom_boxplot(size=2) +
  geom_errorbar(aes(ymin=lower,ymax=upper),linetype = 1,width = 0.5) +
  labs(x = "Wasserversorgung", y = "Belegungswahrscheinlichkeit") +
  theme_classic()

```




Indirekte Wasserversorgung durch Druckwasser mag die Erdkröte in diesem Gebiet scheinbar nicht so sehr.

```
# nur Röhrrichtgürtel wechselt
nd4 <- expand.grid(air = mean(air, na.rm=TRUE),
                  Sum_Rain = mean(Sum_Rain),
                  Wasserversorgung= "indirekt",
                  Roehrichtguertel_13 = seq(0,100,5))

det.4 <- round(predict(fmx2.fin, type="psi" , newdata=nd4, appedData = TRUE ),2)
#det.4
df.det4 <- as.data.frame(cbind(nd4,det.4))
head(df.det4)
```

```
##      air Sum_Rain Wasserversorgung Roehrichtguertel_13 Predicted SE lower
## 1 10.54167 81.71667      indirekt          0      0.39 0.56 0.01
## 2 10.54167 81.71667      indirekt          5      1.00 0.00 0.00
## 3 10.54167 81.71667      indirekt         10      1.00 0.00 0.00
## 4 10.54167 81.71667      indirekt         15      1.00 0.00 0.00
## 5 10.54167 81.71667      indirekt         20      1.00 0.00 0.00
## 6 10.54167 81.71667      indirekt         25      1.00 0.00 0.00
## upper
## 1 0.99
## 2 1.00
## 3 1.00
## 4 1.00
## 5 1.00
## 6 1.00
```

```
ggplot(data = df.det4, aes(x = Roehrichtguertel_13, y = Predicted)) +
  geom_ribbon(aes(ymin = lower, ymax = upper), fill = "gray") +
  stat_smooth(method = "loess", col = "black", se = FALSE) +
  labs(x = "Röhrichtgürtel [%]", y = "Vorkommenswahrscheinlichkeit") +
  theme_classic()
```



Ab 25% Röhrichtgürtel kommt die Erdkröte sicher vor.

Analog könnte man nun auch die Kolonisation und Extinktion mit Parametern hinterlegen.

Weiterhin können wir wieder die Occupancy-Werte (Vorkommenswahrscheinlichkeit) von allen Jahren berechnen lassen:

```
projected(fmx2.fin)
```

```
##           1           2           3  4  5           6
## unoccupied 0.108893 0.1186827 0.2910923 0.5 0.5 0.03371082
## occupied   0.891107 0.8813173 0.7089077 0.5 0.5 0.96628918
```

Die Belegung nahm von 2013 bis 2015 leicht ab, war aber 2018 am höchsten. Damit unterscheiden sich die Werte leicht, jedoch nicht drastisch von den ursprünglich berechneten Werten ohne Kovariablen.

## Literaturverzeichnis

Bartoń, K. 2024. MuMIn: Multi-Model Inference. R package version 1.48.4, <https://CRAN.R-project.org/package=MuMIn>.

- Fiske, I. & R. Chandler. 2011. unmarked: An R Package for Fitting Hierarchical Models of Wildlife Occurrence and Abundance. *Journal of Statistical Software*, 43(10): 1-23.
- Kellner K.F., A.D. Smith, J.A. Royle, M. Kery, J.L. Belant, & R.B. Chandler. 2023. The unmarked R package: Twelve years of advances in occurrence and abundance modelling in ecology. *Methods in Ecology and Evolution* 14(6): 1408-1415.
- MacKenzie, D.I., J.D. Nichols, J.A. Royle, K.H. Pollock, L.L. Bailey, & J.E. Hines. 2018. *Occupancy Estimation and Modeling. Inferring Patterns and Dynamics of Species Occurrence*. Second Edition. Academic Press, London.
- Weir L.A., I.J. Fiske, & J. Royle J. 2009. Trends in Anuran Occupancy from Northeastern States of the North American Amphibian Monitoring Program. *Herpetological Conservation and Biology*. 4(3): 389-402.
- Wickham, H. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.