

Beispiel 7.3. Berechnung der Tagesüberlebensraten von Stockentennestern (*Anas platyrhynchos*) für konstante und variable Überlebensraten

Kapitel 7.3.1.1 aus Henle, K., A. Grimm-Seyfarth & B. Gruber: Erfassung und Analyse von Tierpopulationen. Ulmer Verlag

Annegret Grimm-Seyfarth

2025-04-18

Die Schätzung des Nesterfolgs und die Bewertung von Faktoren, die möglicherweise mit den Überlebensraten von Nestern zusammenhängen, sind zentrale Aspekte vieler Studien über Vogelpopulationen. Eine Vielzahl verschiedener Methoden zur Schätzung der Überlebensrate von Nestern wurde entwickelt, insbesondere mit verschiedenen Modellierungsansätzen. Trotz dieser Fortschritte wird immer noch die Ad-hoc-Methode von Mayfield (Mayfield 1961) verwendet oder, in einigen Fällen, der Maximum-Likelihood-Schätzer von Johnson (1979) und Bart & Robson (1982), so wie wir sie in Kapitel 7.3.1.1 des Buches vorstellen. Diese Methoden wurden um die Einführung von Kovariablen ergänzt (Dinsmore et al. 2002, Stephens 2003, Shaffer 2004; siehe Kap. 7.3.1.2 des Buches). Dabei wird ein generalisierter linearer gemischter Modellansatz genutzt, der die selbe binomiale Likelihood nutzt wie im Originalmodell, aber zusätzlich tägliche Nestüberlebensraten als Funktion von nest-, gruppen- oder zeitspezifischen Kovariablen modelliert werden. Multipliziert man alle Tagesüberlebensraten, erhält man den Nesterfolg. Lässt man die Kovariablen weg, erhält man die Standard-Mayfield-Methode, angepasst nach Johnson (1979) und Bart & Robson (1982). In diesem Beispiel stellen wir diese Methode anhand eines Beispieldatensatzes für Stockenten (*Anas platyrhynchos*) vor.

Die Daten stammen aus dem Jahr 2000 aus der Region Coteau, North Dakota, und sind Teil einer Langzeitstudie (Stephens 2003). Der Datensatz enthält Informationen aus insgesamt 1.585 Beobachtungen an 565 Nestern, die an 18 Standorten während einer Nistsaison von 90 Tagen regelmäßig aufgesucht wurden. Die Intervalllänge betrug in der Regel 4, 5 oder 6 Tage (Durchschnitt = 4,66 Tage, Standardabweichung = 1,41 Tage). Dieses Beispiel wird von Rotella et al. (2004) beschrieben. Wir nutzen dazu das R-Paket RMark (Laake 2013) und zur Visualisierung ggplot2 (Wickham 2016).

```
# check.packages function: install and load multiple R packages.
# Function from: https://gist.github.com/smithdanielle/9913897
check.packages <- function(pkg){
  new.pkg <- pkg[!(pkg %in% installed.packages()[, "Package"])]
  if (length(new.pkg))
    install.packages(new.pkg, dependencies = TRUE, type = "source")
  sapply(pkg, require, character.only = TRUE)
}

# benoetigte R pakete
pakete <- c("RMark", "ggplot2")

# Pruefe und installiere
check.packages(pakete)

## RMark ggplot2
```

```
## TRUE TRUE
```

Weitere Informationen zur Nutzung des Paketes finden sich hier:

<https://rdrr.io/cran/RMark/man/mallard.html>

<https://cran.r-project.org/web/packages/RMark/RMark.pdf>

Daten einlesen und prozessieren

Die Daten sind unter dem Datensatz *mallard* in RMark enthalten.

```
data(mallard)
head(mallard)
```

```
## FirstFound LastPresent LastChecked Fate Freq Robel PpnGrass Native Planted Wetland
## 1          73          89          89    0    1 6.000  0.8002      0      0      0
## 2          63          90          90    0    1 3.750  0.6684      0      1      0
## 3          70          70          76    1    1 3.750  0.8002      0      1      0
## 4          63          81          85    1    1 3.125  0.6684      1      0      0
## 5          61          61          66    1    1 4.500  0.6684      0      1      0
## 6          57          57          61    1    1 4.250  0.6684      0      1      0
## Roadside AgeFound AgeDay1
## 1         1        13     -59
## 2         0         5     -57
## 3         0        13     -56
## 4         0         6     -56
## 5         0         4     -56
## 6         0         1     -55
```

Folgende Variablen sind im Datensatz enthalten:

FirstFound der Tag an dem das Nest zuerst gefunden wurde

LastPresent der letzte Tag an dem die Küken anwesend waren

LastChecked der letzte Tag an dem das Nest geprüft wurde

Fate das Schicksal des Nestes; 0=geschlüpft und 1=geplündert

Freq die Frequenz von Nestern mit Daten; immer 1 in diesem Beispiel

Robel Robel-Messung der Vegetationsdicke

PpnGrass Anteil Gras in der Nähe des Nests

Native Dummy-Variable 0/1; 1 bei einheimischer Vegetation

Planted Dummy-Variable 0/1; 1 wenn Bepflanzung

Wetland Dummy-Variable 0/1; 1 wenn Feuchtgebietsvegetation

Roadside Dummy-Variable 0/1; 1 wenn Straßenrandvegetation

AgeFound Alter des Nestes in Tagen an dem Tag, an dem das Nest gefunden wurde

AgeDay1 Alter des Nestes zu Beginn der Studie

Das Beispiel führt die 9 Modelle aus, die im Kapitel “Nest Survival” der Gentle Introduction to MARK verwendet werden und die in Tabelle 3 (Seite 198) von Rotella et al. (2004) dargestellt sind. Das unten gezeigte Original-Mallard-Beispiel verwendet einzelne Aufrufe der Funktion `mark`. Dies ist nicht so effizient wie die Verwendung von `mark.wrapper` und kann zu Schwierigkeiten führen, wenn verschiedene Gruppenargumente

verwendet werden und eine Modellmittelung (model averaging) versucht wird. Im Anschluss wird daher der effizientere Ansatz für das Originalbeispiel gezeigt.

Im Datensatz beschreiben die Spalten Native, Planted, Wetland und Roadside vier verschiedenen Habitate. Wir kreieren daraus eine Habitatvariable mit vier Level, die als Gruppenvariable genutzt werden kann.

```
mallard$habitat <- ifelse(mallard$Native == 1, "Native",
                          ifelse(mallard$Planted == 1, "Planted",
                                ifelse(mallard$Roadside == 1, "Roadside",
                                      "Wetland")))
mallard$habitat <- as.factor(mallard$habitat)
```

Nun werden die Daten für die Analyse in RMark prozessiert. Die notwendigen Daten sind hierbei der Name des Datensatzes, die Anzahl Beobachtungen (90), das gewünschte Modell ("Nest" stellt hierbei die Mayfield Methode dar)

```
mallard.pr <- process.data(mallard,
                           nocc=90,
                           model="Nest",
                           groups=("habitat"))
```

Analyse eines einzelnen Modelles

Zunächst zeigen wir, wie man ein einzelnes Modell in RMark aufrufen würde.

```
Hab=mark(mallard,nocc=90,model="Nest",
         model.parameters=list(S=list(formula=~habitat)), groups="habitat")
```

Eine Zusammenfassung des Modells bekommen wir mittels *Summary*. Man kann aber auch den kompletten Output mit Modellstruktur als Textfile kreieren lassen und dann separat abspeichern, so wie es auch mit MARK möglich ist. Dazu ruft man das Modell *Hab* auf.

```
summary(Hab)
```

```
## Output summary for Nest model
## Name : S(~habitat)
##
## Npar : 4
## -2lnL: 1563.951
## AICc : 1571.957
##
## Beta
##           estimate      se      lcl      ucl
## S:(Intercept)  2.8629310 0.0992683  2.6683653 3.0574968
## S:habitatPlanted 0.2226794 0.1273493 -0.0269253 0.4722841
## S:habitatRoadside 0.2111144 0.2356357 -0.2507317 0.6729604
## S:habitatWetland 0.0929133 0.2454492 -0.3881670 0.5739937
##
##
## Real Parameter S
##           1          2          3          4          5          6
## Group:habitatNative 0.9459833 0.9459833 0.9459833 0.9459833 0.9459833 0.9459833
## Group:habitatPlanted 0.9562953 0.9562953 0.9562953 0.9562953 0.9562953 0.9562953
## Group:habitatRoadside 0.9558094 0.9558094 0.9558094 0.9558094 0.9558094 0.9558094
## Group:habitatWetland 0.9505390 0.9505390 0.9505390 0.9505390 0.9505390 0.9505390
##           7          8          9         10         11         12
```

[illegible]

##	73	74	75	76	77	78
## Group:habitatNative	0.9459833	0.9459833	0.9459833	0.9459833	0.9459833	0.9459833
## Group:habitatPlanted	0.9562953	0.9562953	0.9562953	0.9562953	0.9562953	0.9562953
## Group:habitatRoadside	0.9558094	0.9558094	0.9558094	0.9558094	0.9558094	0.9558094
## Group:habitatWetland	0.9505390	0.9505390	0.9505390	0.9505390	0.9505390	0.9505390
##	79	80	81	82	83	84
## Group:habitatNative	0.9459833	0.9459833	0.9459833	0.9459833	0.9459833	0.9459833
## Group:habitatPlanted	0.9562953	0.9562953	0.9562953	0.9562953	0.9562953	0.9562953
## Group:habitatRoadside	0.9558094	0.9558094	0.9558094	0.9558094	0.9558094	0.9558094
## Group:habitatWetland	0.9505390	0.9505390	0.9505390	0.9505390	0.9505390	0.9505390
##	85	86	87	88	89	
## Group:habitatNative	0.9459833	0.9459833	0.9459833	0.9459833	0.9459833	
## Group:habitatPlanted	0.9562953	0.9562953	0.9562953	0.9562953	0.9562953	
## Group:habitatRoadside	0.9558094	0.9558094	0.9558094	0.9558094	0.9558094	
## Group:habitatWetland	0.9505390	0.9505390	0.9505390	0.9505390	0.9505390	

Wir sehen in der Zusammenfassung den Namen des Modells [S(~habitat) ist die Überlebenswahrscheinlichkeit (Survival) in Abhängigkeit des Habitates], eine Zusammenfassung der Anzahl Parameter [Npar] und des AICc, die Beta-Schätzungen (estimate - Schätzwert, se = Standardfehler, lcl - unteres Konfidenzintervall, ucl - oberes Konfidenzintervall), die uns lediglich die Richtung des Einflusses eines Parameters zeigen, und die real geschätzten Parameter.

Modellvergleiche mit Wrapper-Funktion

Die oben angesprochenen 9 Modelle stellen wir hier in der Wrapper-Funktion zusammen. Sie umfassen (beispielhaft für alle anderen möglichen Kombinationen) die folgenden Modelle:

```
run.mallard <- function() {
  # 1. konstante Tagesüberlebensrate SD (d. h., Standard-Mayfield-Methode)
  S.Dot = list(formula = ~1)

  # 2. SD variiert nach Habitattyp
  # Habitat wird hier als Faktor genutzt (wie neu kreiert)
  # Im Output gibt es demnach SD geschätzt je Habitattyp
  S.Hab = list(formula = ~habitat)

  # 3. SD variiert nach Robel-Vegetationsdicke
  S.Robel = list(formula = ~Robel)

  # 4. SD variiert nach Anteil Gras in der Nähe des Nests
  S.PpnGr = list(formula = ~PpnGrass)

  # 5. SD hat einen zeitlichen Trend
  S.TimeTrend = list(formula = ~Time)

  # 6. SD variiert mit Alter des Nestes
  S.Age = list(formula = ~NestAge)

  # 7. SD variiert nach Alter des Nestes und Habitattyp
  S.AgeHab = list(formula = ~NestAge + habitat)

  # 8. SD variiert nach Alter des Nestes und Vegetationsdicke
  S.AgeRobel = list(formula = ~NestAge + Robel)
```

```

# 9. SD variiert nach Alter des Nestes und Anteil Gras in der Nähe des Nestes
S.AgePpnGrass = list(formula = ~NestAge + PpnGrass)

# Eine Modelltabelle und Liste aller Modell wird kreiert
mallard.model.list = create.model.list("Nest")

mallard.results = mark.wrapper(mallard.model.list,
                               data = mallard.pr,
                               adjust = FALSE, delete=TRUE)
}

```

Nachfolgend werden diese neun Modelle gerechnet. Dies dauert im Normalfall bis zu 2 Minuten.

```
mallard.results <- run.mallard()
```

```

# Aufrufen der Tabelle für Modellvergleiche
mallard.results

```

##	model	npar	AICc	DeltaAICc	weight	Deviance
## 3	S(~NestAge + PpnGrass)	3	1563.010	0.000000	0.464766129	1557.006
## 1	S(~NestAge)	2	1564.066	1.056440	0.274051094	1560.064
## 4	S(~NestAge + Robel)	3	1565.906	2.896000	0.109238584	1559.902
## 2	S(~NestAge + habitat)	5	1567.344	4.333984	0.053225761	1557.334
## 7	S(~PpnGrass)	2	1567.368	4.358240	0.052584141	1563.366
## 5	S(~1)	1	1569.117	6.107033	0.021933560	1567.116
## 8	S(~Robel)	2	1570.775	7.765340	0.009572214	1566.773
## 9	S(~Time)	2	1570.826	7.816940	0.009328410	1566.824
## 6	S(~habitat)	4	1571.957	8.947615	0.005300107	1563.951

Das Ergebnis ist eine Modellselektionstabelle (siehe Kapitel 9.3 des Buches). Das Modell mit dem geringsten AIC-Wert ist das beste Modell. Daher wissen wir nun, dass die Tagesüberlebensrate vom Alter des Nestes und dem Anteil Gras in der Nähe des Nestes beeinflusst wird. Das konstante Modell (Mayfield-Methode) ist ganze 6,1 AIC-Punkte hinter dem besten Modell. Die Standard-Mayfield-Methode würde also in diesem Fall nicht die präzisesten Schätzungen liefern.

Die Ergebnisse könnte man exportieren (auskommentiert, # muss also entfernt werden). Außerdem kann die Modellselektionstabelle mit dem Befehl *sink* als Textfile gespeichert werden. Mit *print* lässt man es sich in R anzeigen, mit einem weiteren *sink* verschwindet es wieder.

```

#export.MARK(mallard.results$S.Age$data,
#            "MallDSR",
#            mallard.results,
#            replace = TRUE,
#            ind.covariates = "all")
sink("results.table.txt")
print(mallard.results)
sink()

```

Die Modellnamen, die wir initial vergeben haben, ruft man folgender Weise noch einmal auf:

```
names(mallard.results)
```

##	[1]	"S.Age"	"S.AgeHab"	"S.AgePpnGrass"	"S.AgeRobel"	"S.Dot"
##	[6]	"S.Hab"	"S.PpnGr"	"S.Robel"	"S.TimeTrend"	"model.table"

Ergebnisse Mayfield-Methode (konstant)

Entsprechend können wir die Ergebnisse des konstanten Modells (nach der klassischen Mayfield-Methode) aufrufen als:

```
# Schätzwerte (nur Schnittpunkt y-Achse in diesem Fall)
```

```
mallard.results$S.Dot$results$beta
```

```
##              estimate      se      lcl      ucl
## S:(Intercept) 3.005653 0.0576808 2.892598 3.118707
```

```
# reale Parameter
```

```
mallard.results$S.Dot$results$real
```

```
##              estimate      se      lcl      ucl fixed note
## S gNative a0 t1 0.9528288 0.0025925 0.9474793 0.9576578
```

Nach der klassischen Mayfield-Methode haben die Nester also eine Tagesüberlebensrate von 0,95 [0,947; 0,958].

Ergebnisse Habitattyp

Analog können wir uns die Ergebnisse variierend nach Habitattyp anschauen.

```
# in einem Texteditor (auskommentiert, # müsste entfernt werden)
```

```
#mallard.results$S.Hab
```

```
# die Designmatrix
```

```
mallard.results$S.Hab$design.matrix
```

```
##              S:(Intercept) S:habitatPlanted S:habitatRoadside S:habitatWetland
## S gNative a0 t1          1                0                0                0
## S gPlanted a0 t1         1                1                0                0
## S gRoadside a0 t1        1                0                1                0
## S gWetland a0 t1         1                0                0                1
```

```
# die Schätzwerte
```

```
# neben den Schnittpunkt mit der y-Achse je einen pro Habitattyp  
# wobei "Native" im Schnittpunkt mit der y-Achse versteckt ist
```

```
mallard.results$S.Hab$results$beta
```

```
##              estimate      se      lcl      ucl
## S:(Intercept) 2.8629310 0.0992683 2.6683653 3.0574968
## S:habitatPlanted 0.2226794 0.1273493 -0.0269253 0.4722841
## S:habitatRoadside 0.2111144 0.2356357 -0.2507317 0.6729604
## S:habitatWetland 0.0929133 0.2454492 -0.3881670 0.5739937
```

```
# die Varianz-Kovarianz-Matrix der Schätzwerte
```

```
mallard.results$S.Hab$results$beta.vcv
```

```
##              ROW1      ROW2      ROW3      ROW4
## [1,] 0.009854186 -0.009854186 -0.009854185 -0.009854183
## [2,] -0.009854186 0.016217853 0.009854185 0.009854183
## [3,] -0.009854185 0.009854185 0.055524199 0.009854181
## [4,] -0.009854183 0.009854183 0.009854181 0.060245288
```

```
# Die geschätzten Tagesüberlebensraten
```

```
# hier also ein Schätzwert pro Habitat
```

```
mallard.results$S.Hab$results$real
```

```
##              estimate      se      lcl      ucl fixed note
## S gNative a0 t1  0.9459833 0.0050725 0.9351339 0.9551051
## S gPlanted a0 t1  0.9562953 0.0033341 0.9492739 0.9623833
## S gRoadside a0 t1 0.9558094 0.0090265 0.9343297 0.9704853
## S gWetland a0 t1  0.9505390 0.0105538 0.9252465 0.9675738
```

Wir sehen, dass die Tagesüberlebensraten sich zwischen den Habitaten nicht wirklich unterscheiden. Es wundert also nicht, dass das Modell, welches Habitat als Parameter enthielt, das schlechteste Modell in der Modellselektionstabelle war.

Ergebnisse bestes Modell

Schauen wir uns nun die Ergebnisse des besten Modells an.

```
mallard.results$S.AgePpnGrass$results$beta
```

```
##              estimate      se      lcl      ucl
## S:(Intercept) 2.4255372 0.1883912 2.0562904 2.7947841
## S:NestAge      0.0187746 0.0074639 0.0041452 0.0334039
## S:PpnGrass     0.3689373 0.2104534 -0.0435515 0.7814260
```

```
mallard.results$S.AgePpnGrass$results$beta.vcv
```

```
##              ROW1      ROW2      ROW3
## [1,]  0.0354912622 -0.0009432735 -0.0247792326
## [2,] -0.0009432735  0.0000557105 -0.0001137064
## [3,] -0.0247792326 -0.0001137064  0.0442906466
```

Sowohl das Alter, als auch der Anteil umgebenden Grases erhöhen die Tagesüberlebensraten. Da dies kontinuierliche Parameter sind, können wir nicht einfach die Schätzungen der Tagesüberlebensraten aufrufen. Ein wenig Kosmetik ist hier nötig.

Abhängigkeit vom Alter des Nestes

```
# Objektnamen vereinfachen und Modell speichern
AgePpnGrass <- mallard.results$S.AgePpnGrass
# Designmatrix bauen, die ausgewählte Alter und PpnGrass Werte enthält
# Relevante Alter für Stockenten wären 1 bis 35
# Für PpnGrass nutzen wir zunächst den Wert 0,5
fc <- find.covariates(AgePpnGrass,mallard)
fc$value[1:35] <- 1:35 # die ersten 35 Nester bekommen 1:35
fc$value[fc$var == "PpnGrass"] <- 0.5 # neuer Wert für PpnGrass
design <- fill.covariates(AgePpnGrass, fc) # Designmatrix füllen
# Tagesüberlebensraten schätzen lassen (erste 35 Zeilen)
AgePpn.survival <- compute.real(AgePpnGrass, design = design)[1:35, ]
# Kovariablenspalte einfügen
AgePpn.survival <- cbind(design[1:35, c(2:3)], AgePpn.survival)
colnames(AgePpn.survival) <- c("Age", "PpnGrass", "DSR", "seDSR", "lclDSR",
                              "uclDSR")
# hierbei bezeichnet DSR die daily survival rate (Tagesüberlebensrate)
# Schätzwerte anzeigen lassen (erste 10 Zeilen)
head(AgePpn.survival,10)
```


```
##      Age PpnGrass      DSR      seDSR      lclDSR      uclDSR NA
## 1      1      0.5 0.9326910 0.008842666 0.9131490 0.9480860
## 2      2      0.5 0.9338601 0.008288313 0.9156409 0.9483664
## 3      3      0.5 0.9350104 0.007754589 0.9180548 0.9486538
```



```
## 4    4      0.5 0.9361419 0.007241811 0.9203908 0.9489495
## 5    5      0.5 0.9372551 0.006750421 0.9226490 0.9492549
## 6    6      0.5 0.9383502 0.006281023 0.9248290 0.9495719
## 7    7      0.5 0.9394274 0.005834413 0.9269304 0.9499026
## 8    8      0.5 0.9404870 0.005411620 0.9289518 0.9502496
## 9    9      0.5 0.9415292 0.005013953 0.9308916 0.9506162
## 10  10     0.5 0.9425542 0.004643045 0.9327475 0.9510061
```

Plotten wir das Ganze mit ggplot:

```
ggplot(AgePpn.survival, aes(x = Age, y = DSR)) +
  geom_line() +
  geom_ribbon(aes(ymin = lc1DSR, ymax = uc1DSR), alpha = 0.3) +
  xlab("Nestalter (Tage)") +
  ylab("Geschätzte Tagesüberlebensrate") +
  theme_bw()
```



Wir sehen den Anstieg der Tagesüberlebensrate mit dem Nestalter. Grau hinterlegt ist das 95%-Konfidenzintervall.

Abhängigkeit vom Anteil Gras um das Nest

Wir nutzen hier die verbleibenden Zeilen der Schätzwerte aus dem obigen Datenframe.

```
# Diesmal legen wir ein mittleres Nestalter fest, 17
fc$value[1:89] <- 17
# Dann bestimmen wir verschiedene Werte für PpnGrass
fc$value[fc$var == "PpnGrass"] <- seq(0.01, 0.99, length = 89)
# Designmatrix ausfüllen
```

```

design <- fill.covariates(AgePpnGrass,fc)
# Tagesüberlebensraten schätzen lassen
AgePpn.survival <- compute.real(AgePpnGrass, design = design)
# Kovariablenspalten hinzufügen
AgePpn.survival <- cbind(design[ , c(2:3)], AgePpn.survival)
colnames(AgePpn.survival) <-
  c("Age", "PpnGrass", "DSR", "seDSR", "lclDSR", "uclDSR")
# Schätzwerte anschauen (erste 10)
head(AgePpn.survival,10)

```

```

##   Age  PpnGrass      DSR      seDSR    lclDSR    uclDSR NA
## 1   17 0.01000000 0.9398226 0.007793762 0.9226061 0.9534027
## 2   17 0.02113636 0.9400546 0.007646214 0.9231940 0.9534007
## 3   17 0.03227273 0.9402857 0.007500037 0.9237768 0.9533993
## 4   17 0.04340909 0.9405160 0.007355241 0.9243545 0.9533987
## 5   17 0.05454545 0.9407454 0.007211839 0.9249269 0.9533987
## 6   17 0.06568182 0.9409740 0.007069845 0.9254943 0.9533995
## 7   17 0.07681818 0.9412018 0.006929274 0.9260565 0.9534011
## 8   17 0.08795455 0.9414288 0.006790140 0.9266135 0.9534036
## 9   17 0.09909091 0.9416549 0.006652462 0.9271653 0.9534068
## 10  17 0.11022727 0.9418802 0.006516258 0.9277119 0.9534111

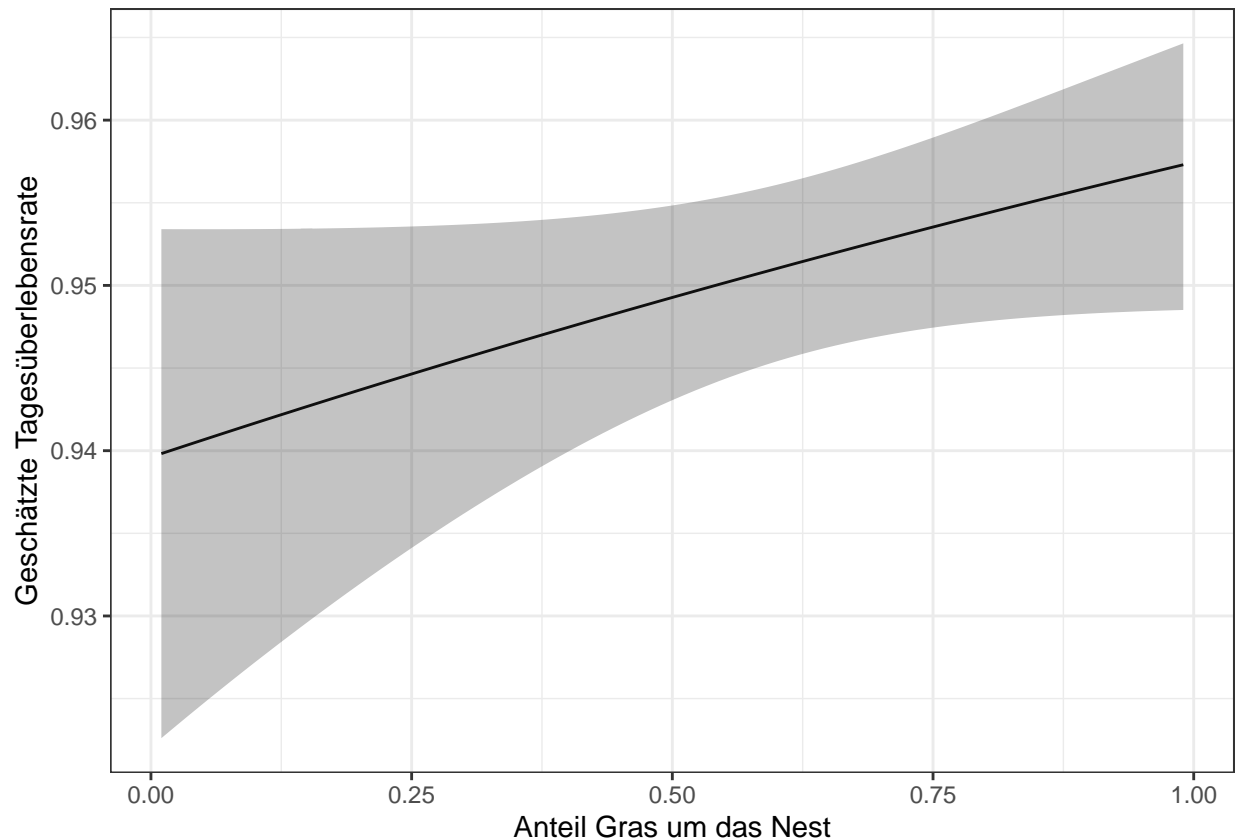
```

Plotten wir das Ganze mit ggplot:

```

ggplot(AgePpn.survival, aes(x = PpnGrass, y = DSR)) +
  geom_line() +
  geom_ribbon(aes(ymin = lclDSR, ymax = uclDSR), alpha = 0.3) +
  xlab("Anteil Gras um das Nest") +
  ylab("Geschätzte Tagesüberlebensrate") +
  theme_bw()

```



Auch hier sehen wir den Anstieg der Tagesüberlebensrate mit dem Anteil Gras um das Nest. Das 95%-Konfidenzintervall ist in grau dargestellt.

Literaturverzeichnis

- Bart, J., D.S. Robson. 1982. Estimating survivorship when the subjects are visited periodically. *Ecology* 63: 1078–1090.
- Dinsmore, S.J., G.C. White, F.L. Knopf. 2002. Advanced techniques for modeling avian nest survival. *Ecology* 83: 3476–3488.
- Johnson, D.H. 1979. Estimating nest success: the Mayfield method and an alternative. *Auk* 96: 651–661.
- Laake, J.L. 2013. RMark: An R Interface for Analysis of Capture-Recapture Data with MARK. AFSC Processed Rep 2013-01, 25p. Alaska Fish. Sci. Cent., NOAA, Natl. Mar. Fish. Serv., 7600 Sand Point Way NE, Seattle WA 98115.
- Mayfield, H.F. 1961. Nesting success calculated from exposure. *Wilson Bulletin* 73: 255–261.
- Rotella, J.J., Dinsmore, S.J., Shaffer, T.L. 2004. Modeling nest–survival data: a comparison of recently developed methods that can be implemented in MARK and SAS. *Animal Biodiversity and Conservation* 27: 187–205.
- Shaffer, T.L. 2004. A unified approach to analyzing nest success. *Auk* 121: 526–540.
- Stephens, S.E. 2003. The influence of landscape characteristics on duck nesting success in the Missouri Coteau Region of North Dakota. Ph.D. Dissertation, Montana State University.
- Wickham, H. 2016. ggplot2: Elegant Graphics for Data Analysis. Springer-Verlag New York.